

MSA와 단백질 구조 예측

진화 관계와 대안 구조 탐색

진화 관계를 읽고, 다중서열정렬에서 구조 예측의 단서를 찾기

깊이·클러스터링·마스킹으로 대안 구조를 탐색하는 3시간

Homology: 얼마나 닮았나보다 어디에서 왔나

용어	무엇을 말하나
Homology	공통 조상에서 유래한 관계
Identity	정렬에서 같은 잔기의 비율
Similarity	정의한 점수 체계에서 유사한 잔기 관계

상동성(homology)은 공통 조상에서 유래했다는 관계

“70% homology” 대신 “정의한 정렬에서 70% identity”라고 표현

Ortholog와 paralog: 갈라진 사건을 묻는다

관계	기준 사건	기억할 점
Ortholog	종 분화(Speciation, S)	기능 동일성을 보장하지 않음
Paralog	유전자 중복(Duplication, D)	같은 종 또는 다른 종에 존재


두 유전자의 가장 최근 공통 조상에서 일어난 사건을 확인

종 이름·서열 유사도·기능의 같고 다름만으로 정하지 않음


Species tree와 gene tree는 다른 질문

교육용 가상 예시

Species tree



Gene tree



S = 종 분화, D = 유전자 중복


A와 B는 종 이름; A_g1 등은 유전자 이름

Species tree: 종들의 분기 관계

Gene tree: 특정 유전자 가족의 계보와 중복·소실

예제 1: 종 분화보다 먼저 중복되었다면

교육용 가상 계통수: 중복 → 종 분화



D에서 1번·2번 유전자 계열이 먼저 나뉨


두 S는 같은 A-B 종 분화를 각 유전자 계열에서 표시

A_1-B_1은 ortholog; A_1-A_2와 A_1-B_2는 paralog

같은 종 안의 관계와 다른 종 사이의 관계를 모두 확인

예제 2: 종 분화 뒤에 중복되었다면

교육용 가상 계통수: 종 분화 → 중복



A 계통에만 중복이 생긴 경우

A_1-B_1과 A_2-B_1은 각각 orthology 관계

A_1과 A_2는 서로 paralog

A_1과 A_2는 각각 B_1의 ortholog: B_1에 대한 co-orthologs

Paralog는 종 안에도, 종 사이에도 있다

관찰 또는 용어	해석 기준
Within-species paralog	같은 종의 두 유전자; 조상 중복 시점은 별도 확인
Between-species paralog	다른 종의 두 유전자; 공통 조상 노드는 D
Inparalog / outparalog	기준 종 분화 뒤 / 앞의 중복에서 유래

“같은 종이면 paralog, 다른 종이면 ortholog”는 불완전한 규칙

In-/out-paralog는 비교하는 종 분화 시점에 대한 상대적 용어

유전자 소실: 남은 하나끼리 비교하면 생기는 착시

교육용 가상 계통수: 중복 뒤 서로 다른 사본 소실



현재 관찰되는 유전자는 A_1과 B_2


현재 사본 수와 과거 분기 사건을 구분

각 종에 한 개씩 남았어도 일대일 ortholog라는 보장은 없음

다른 종의 서열·유전자 계통수·주변 유전자 정보가 판별에 도움

실습 1: 가장 최근 공통 조상에 표시하기

교육용 가상 계통수



가지 길이는 의미 없음

현재 이름이 아니라 가장 최근 공통 조상 사건으로 판정

① A_x-A_y ② A_x-B_z ③ A_y-B_z 관계를 판정

각 쌍의 공통 조상에 동그라미 → S/D → 관계 이름

짝과 비교: co-ortholog라고 부를 때 기준 상대는 누구인가?

Ortholog여도 기능이 완전히 같지는 않다

알 수 있는 것	추가 확인할 것
Orthology / paralogy	기원과 분기 사건
높은 서열 동일성	정렬 길이·도메인 구성·진화 관계
비슷한 예측 구조	기질·활성·발현·실험 조건

진화 관계는 기능 추론의 근거이며 기능 실험의 대체물이 아님

최고 유사도 hit 하나만으로 orthology 또는 기능을 확정하지 않음

유전자 가족에서 MSA로: 대응 위치를 제안한다

Multiple sequence alignment(MSA): 여러 상동 서열의 대응 위치를 정렬
정렬은 비교를 위한 가설이며 모든 열이 정확하다는 보장은 없음
너무 먼 서열·부분 서열·다른 도메인 구성은 별도 점검

MSA 읽기: 행·열·query·gap

교육용 가상 서열: 실제 단백질 아님

정렬 열	123456789
query	AC-DEFGHI
seq_A	ACQDEYGHI
seq_B	AC-NEFG-I
seq_C	AS-DEF-HI

4행 × 9열; query의 실제 길이는 8잔기

3열의 Q는 query에 대응 잔기가 없는 삽입 위치

행(row)은 서열, 열(column)은 대응 위치, “-”는 gap

Query는 이번 분석의 기준 서열; 항상 조상 서열이라는 뜻은 아님

Gap 하나가 잔기 번호를 바꾼다

교육용 가상 서열

정렬 열	1	2	3	4	5	6	7	8	9
query	A	C	-	D	E	F	G	H	I
query 잔기	1	2	-	3	4	5	6	7	8

정렬 4열 = query의 D3

원래 query 서열: ACDEFGHI

정렬 열 번호와 query 잔기 번호를 구분해서 기록

Gap만으로 삽입·결실의 진화 방향을 확정할 수 없음

FASTA: 이름 줄과 서열 줄부터 읽기

```
>query_synthetic    educational example  
ACDEFGHI  
>seq_A_synthetic    educational example  
ACQDEYGHI
```

두 서열의 실제 길이는 8과 9

이 텍스트는 정렬 전의 교육용 가상 FASTA

“>”로 시작하는 줄은 이름·설명, 다음 줄은 서열

여러 FASTA 서열이 있다고 자동으로 MSA가 되는 것은 아님

A3M: 대문자와 소문자는 서로 다른 역할

교육용 가상 A3M

```
>query
```

```
ACDEFGHI
```

```
>seq_A
```

```
ACqDEYGH I
```

```
>seq_B
```

```
ACNEFG-I
```

seq_A: q는 삽입, Y는 대응 열의 치환

겉보기 문자 수가 달라도 같은 match 열을 표현 가능

대문자 = match 상태의 잔기; 소문자 = 삽입 잔기; “-” = 결실 표시

Match는 query와 같은 아미노산이라는 뜻이 아님

Coverage와 identity: 분모를 함께 적는다

교육용 정의	계산
Query coverage	짜지어진 query 잔기 수 / query 길이
Identity	같은 잔기 수 / 양쪽에 잔기가 있는 비교 위치 수
보고 예	identity 80%, coverage 25%; 각 분모도 기록

Coverage: query의 어느 정도를 비교했는가?

Identity: 비교한 위치 중 어느 정도가 같은 잔기인가?

실습 2: 짧고 완벽한 hit와 길고 다른 hit

교육용 가상 서열

query ACDEFGHI

A ACDE----

B ACNEYGHI

A의 끝부분 gap은 query 위치를 덮지 않음

Coverage와 identity의 분모를 각각 적기

Query 길이 8; A와 B 각각 coverage와 identity를 계산

분모는 앞 장의 교육용 정의를 사용

전체 query를 설명할 때 어떤 차이를 함께 보고해야 하는가?

Conservation: 한 열에서 무엇이 유지되는가?

교육용 가상 서열

seq_1 ACDK

seq_2 ASDK

seq_3 ACEK

seq_4 ASER

열 1234

보존도는 한 열의 잔기 분포에 대한 질문

“모두 같다”와 “서로 독립적인 근거가 많다”를 구분

한 위치의 잔기 분포를 읽는 것이 보존도(conservation)

보존된 위치는 구조·기능 제약의 후보이며 원인은 추가 확인

Covariation: 두 열의 조합을 읽는다

교육용 가상 패턴: 두 위치만 표시

서열	위치 i	위치 j
seq_1	K	D
seq_2	K	D
seq_3	E	R
seq_4	E	R

각 열의 빈도와 두 열의 조합 빈도는 다름

이 예시는 실제 접촉 정보가 아님

공변이(covariation)는 두 위치의 잔기 분포가 독립적이지 않은 패턴

보존도는 한 열, 공변이는 두 열의 조합을 살핌

공통 조상도 함께 변하는 패턴을 만든다

가능한 원인	추가로 필요한 생각
공통 조상의 패턴 상속	계통적 비독립성
다른 위치를 통한 간접 관계	직접·간접 효과 구분
구조·기능상의 제약	다른 증거 및 실험과 비교

같은 조상에서 물려받은 패턴은 독립적 관측 여러 개가 아님

계통 효과·간접 상관·직접 상호작용을 단순 상관만으로 분리할 수 없음

Raw depth와 Neff: 행 수와 다양성은 다르다

교육용 재가중 예	Raw depth	가중치 합
완전히 동일한 서열 100개	100	$100 \times 1/100 = 1$
서로 기준 이상 유사한 쌍이 없는 100개	100	$100 \times 1 = 100$
실제 MSA	행 수를 기록	정의·유사도 기준·coverage도 기록

Raw depth는 서열 행 수; 같은 서열이 많아도 그대로 증가

Neff는 중복·유사도를 반영하는 지표이며 계산법을 반드시 명시

다음 단계: MSA의 어떤 정보를 바꿀 것인가?

조작	먼저 물을 질문
Depth 조절	몇 행을 남기며 어떤 다양성이 달라지는가?
Clustering	어떤 서열 집단을 골랐는가?
Masking	어떤 열을 가리며 query 번호는 유지되는가?

변경 전후의 행 수·다양성·coverage·query 좌표를 기록

MSA 변경으로 얻은 다른 구조는 검증할 후보이지 상태의 증거가 아님

휴식 · 10분

10분 뒤 다시 시작합니다.

다음 시간: MSA를 예측 모델에 넣는 방법

서열에서 예측 구조까지

Query: 구조를 알고 싶은 단백질의 아미노산 서열

MSA: 진화적으로 관련된 서열을 정렬한 입력

모델: 서열·MSA·선택한 추가 정보를 함께 처리

출력: 원자 좌표와 모델이 추정된 신뢰도

AlphaFold2와 AlphaFold3

항목	AlphaFold2 계열	AlphaFold3
주요 입력	단백질 서열·MSA·template	단백질·핵산·리간드 등
좌표 생성	구조 모듈과 recycling	Diffusion 기반 생성
이 강의에서 역할	MSA 조작의 주요 실습 도구	기본 예측과 확장 적용 비교
해석 원칙	여러 예측을 만들고 검증	별도 검증 후 기법 적용

이 강의의 MSA 조작 사례는 주로 AF2에서 검증되었습니다.

웹 서버와 로컬 실행

웹 서버: 서열과 분자를 입력해 빠르게 시작

로컬 AF3: JSON으로 custom MSA-template 지정

MSA 조작 실습: custom A3M을 받는 ColabFold 활용

실제 예측에는 모델 설치·계산 자원이 필요

Custom MSA의 기본 조건

첫 번째 서열은 예측할 query와 일치

정렬 열은 query의 위치와 대응

A3M의 소문자는 insertion, 대문자·gap은 정렬 열
비교할 때 query·template·모델 버전을 함께 기록

AF3에서 custom MSA 지정

```
"protein": {  
  "id": "A",  
  "sequence": "<full query sequence>",  
  "unpairedMsaPath": "target.a3m",  
  "pairedMsa": "",  
  "templates": []  
}
```

unpairedMsaPath: 직접 준비한 A3M

pairedMsa: 단량체 실습에서는 빈 값

templates: template 비교 조건 고정

아래는 protein 항목의 형식 예시입니다.

실제 FASTA와 A3M을 사용한 완전한 JSON은 [examples/](#)에서 생성합니다.

다른 예측 모델의 역할

도구	주요 역할	이 수업에서 비교할 점
ColabFold / AF2	Custom A3M 예측	MSA 조건별 차이
Boltz-2	여러 분자의 복합체 예측	A3M과 분자 조건
Chai-1	생체분자 복합체 예측	MSA 사용 여부
ESMFold	단일 서열 예측	MSA 없는 비교 기준

모델 간 일치는 참고 근거이며 독립적인 실험 검증은 아닙니다.

한 번에 한 조건씩 비교

Baseline: 원본 MSA와 정해진 seed 목록

Depth: 행 수만 줄여 여러 번 표본 추출

Cluster: 비슷한 서열 집단별 입력

Mask: 정해진 열의 정보만 가리는 조건

기준 예측부터 기록한다

먼저 고정	변경 후보	함께 기록
Query·모델 버전	MSA 행 또는 열	입력 파일·행 수
Template 조건	Seed·dropout	반복 수·실행 설정
구조 비교 구간	한 조건씩 비교	pLDDT·PAE·구조 차이

같은 단백질의 입력 근거를 바꾸어 비교한다.

Query 서열·길이·번호를 먼저 고정한다.

한 번에 바꾸는 조건과 반복 횟수를 기록한다.

행을 줄인다: MSA subsampling

원래 MSA

query	ACDEFGHI
hom1	AC-EYGHI
hom2	ACDEFG-I
hom3	ACNEFGHI

선택한 MSA

query	ACDEFGHI
hom1	AC-EYGHI
hom3	ACNEFGHI


교육용 가상 정렬. Query 행은 유지하고, homolog 행의 일부를 택한다. 열과 query 길이는 유지한다.

행(row) = 정렬에 포함된 서열 하나

Query는 남기고 homolog 행 일부를 선택한다.

행 수 감소는 정보 감소와 다양성 변화를 함께 만든다.

논문 그림 읽기: 얇은 MSA의 효과와 한계




점 하나는 예측 구조 하나: 실험 구조와 비교한다.
MSA 깊이에 따라 구조 분포가 달라진 사례가 있다.
다양성 증가에는 잘못 접힌 구조도 섞일 수 있다.

[del Alamo et al., eLife \(2022\), Fig. 1A \(발체\)](#)

[CC BY 4.0](#)

AF-Cluster: 서열을 먼저 나누어 예측



MSA의 homolog를 서열 유사성으로 나눈다.
각 sub-MSA를 별도로 AF2에 입력한다.
KaiB의 알려진 다른 접힘을 탐색한 사례가 있다.

[Wayment-Steele et al., Nature \(2024\), Fig. 1d \(발췌\)](#)

[CC BY 4.0](#)

각 cluster에도 같은 query가 들어간다

Cluster A 입력

```
>query  
ACDEFGHI  
>hom1  
AC-EYGHI
```

Cluster B 입력

```
>query  
ACDEFGHI  
>hom3  
ACNEFGHI
```

교육용 가상 정렬. 두 입력의 query는 동일하고, 그 아래 homolog 조합만 다르다.

예측 대상 = query, 배경 정보 = homolog 집합

Cluster마다 query를 맨 앞에 다시 넣는다.

Cluster 대표 서열로 query를 바꾸면 대상도 바뀐다.

서열 cluster는 열역학적 상태가 아니다

분류 질문	사용 정보	바로 알 수 없는 것
어떤 서열이 닮았나?	서열 유사성	구조 상태의 수
어떤 진화 관계인가?	유전자·종 계통	상태별 점유율
어떤 구조가 다른가?	좌표·접촉·실험	전환 속도

서열 유사성은 진화적 관련성과 기능 차이를 섞어 담는다.

Ortholog / paralog 구분과 구조 상태 구분은 다른 문제다.

Cluster 수·크기에서 상태 수·점유율을 바로 읽지 않는다.

2025년 논쟁: 비교 조건을 읽는다

자료	핵심 질문	읽을 때 확인
Nature 비판 (2025)	무작위 표본보다 나은가?	표적·표본 수·AF2 설정
JMB 응답 (2025)	진화 신호를 직접 시험했나?	대조군·추가 분석
우리 비교 설계	무엇 하나가 달랐나?	동일 조건·독립 평가

Matters Arising은 무작위 표본 비교와 해석을 비판했다.

저자 응답은 비교 조건과 진화 신호의 역할을 재검토했다.

강의 결론: 같은 조건의 대조군과 독립 검증이 필요하다.

두 가지 clustering을 구별한다

단계	묶는 대상	목적
AF2 이전	MSA 서열 행	다른 입력 근거 만들기
AF2 이후	예측 구조 후보	중복 정리·대표 선택
실험 검증 이후	관찰된 상태	물리적 해석 뒷받침

입력 clustering: 예측 전에 서열을 묶는다.

출력 clustering: 예측 후 구조를 묶는다.

많은 입력 cluster가 같은 구조를 만들 수도 있다.

열을 가린다: unknown X와 gap의 차이

원래		한 열을 X로 마스킹	
query	ACDEFGHI	query	ACDEFGHI
hom1	AC-EYGHI	hom1	AC-XYGHI
hom2	ACDEFG-I	hom2	ACDXFG-I
	↑		↑

교육용 가상 정렬. X = unknown residue, - = gap. Query 첫 행과 전체 정렬 열 수는 바꾸지 않는다.

열(column) = query의 정렬 위치에 대응

X는 종류를 모르는 잔기, -는 정렬의 gap이다.

오늘 실습에서는 query를 보존한 채 정보만 가린다.

SPEACH_AF와 AFsample2는 같은 편집이 아니다

비교	SPEACH_AF 원 방법	AFsample2
편집 기호	A: alanine	X: unknown
위치 선택 근거	초기 구조의 접촉 정보	무작위 MSA 열
Query 처리	원 코드에서 함께 편집	첫 query 행 유지
공통 해석	새 구조 후보 탐색	검증 필요한 후보

SPEACH_AF: 구조 정보를 이용한 alanine 편집

AFsample2: 선택한 MSA 열을 unknown X로 가림

원래 SPEACH_AF는 query도 편집한다는 예외를 확인한다.

논문 그림 읽기: AFsample2의 입력과 출력




그림 a: 행 선택과 열 마스킹을 비교한다.
예측 뒤에는 후보 분석과 독립 검증이 필요하다.
새로운 후보가 곧 실험으로 확인된 중간 상태는 아니다.

[Kalakoti & Wallner, Communications Biology \(2025\), Fig. 1a \(발취\)](#)

FASTA 제목에 open을 쓰면 열릴까?

```
>sample_open  
ACDEFGHI
```

```
>sample_closed  
ACDEFGHI
```

교육용 가상 서열. 같은 문자열에 붙인 이름 두 개이며, open/closed 상태를 지정한 입력이 아니다.

Header는 식별자이며 구조 상태 명령문이 아니다.

MSA 내용과 예측 설정이 같으면 이름만으로 상태를 지정하지 못한다.

복합체에서는 header의 종 정보가 pairing에 쓰일 수 있다.

Seed·dropout·template도 별도 요인이다

요인	바뀌는 것	주의할 해석
Random seed	확률적 계산의 선택	다른 seed ≠ 다른 물리 상태
Inference dropout	계산 중 확률적 교란	온도·시간을 지정하지 않음
Template	참고 구조 정보	유도된 상태·평가 누출 점검
Recycles	예측 내부 반복	분자 운동 시간과 다름

Seed: 반복마다 사용되는 난수의 출발점

Dropout: 지원 구현에서 추론 중 일부 연산을 무작위로 끄

Template: 이미 알려진 구조 정보가 입력에 추가됨

AF2 근거를 AF3에 그대로 옮길 수는 없다

범위	확인된 내용	필요한 추가 확인
AF2 방법 연구	Subsampling·cluster·mask 사례	새 표적에서 대조 비교
로컬 AF3	Custom MSA 입력 지원	구현·설정·모델 차이
AF3 연구 확장	AFsample3 저장소 존재	표적별 검증·근거 수준

이 단원의 대표 논문들은 AF2를 시험했다.

로컬 AF3는 custom MSA를 받을 수 있다.

AF3용 구현의 존재와 검증된 성능을 구별한다.

3분 설계 실습: 공정한 비교를 고르기

설계	조건 1	조건 2
A	Query Q / template 없음 / 5회	Query Q 일부 삭제 / template 있음 / 50회
B	Query Q / 전체 MSA / 10회	Query Q / 선택 MSA / 10회
B의 공통 조건	모델·template·seed 집합	같이 유지

질문: MSA 행 선택의 효과를 알고 싶다.

A/B 중 더 공정한 비교를 고르고 이유를 적는다.

고정할 것 2개, 기록할 것 2개를 짝과 공유한다.

대표 후보는 품질과 다양성을 함께 본다

가상 후보	관찰	판단 질문
A	Core 양호·기준 형태	기준 대표인가?
B	Core 양호·도메인 배치 다름	PAE와 실험이 뒷받침하나?
C	큰 차이·국소 충돌·낮은 확신	다른 상태인가, 오류인가?
D	A와 거의 같은 구조	중복을 줄일 수 있나?

먼저 원자 충돌·비정상 구조·낮은 확신 영역을 점검한다.

안정된 core를 기준으로 겹친 뒤 차이를 비교한다.

서로 다른 후보를 남기고 실험 근거와 대조한다.

pLDDT·PAE를 상태 확률로 읽지 않는다

숫자	말할 수 있는 것	직접 뜻하지 않는 것
pLDDT 높음	국소 구조를 자신 있게 예측	안정성·결합력·점유율
PAE 낮음	상대 배치를 자신 있게 예측	이동 속도·전환 빈도
100개 중 70개	이 설정의 생성 빈도	평형에서 70% 존재

pLDDT: 국소 구조에 대한 모델의 확신

PAE: 상대 위치에 대한 예상 오차(Å)

후보가 70% 나왔다는 사실만으로 점유율 70%는 아니다.

여러 구조를 얻은 뒤 남는 질문

종이·구두 응답 또는 컴퓨터 실습

가능한 주장: 이 조건에서 서로 다른 구조 후보를 얻었다.

추가 근거 필요: 실제 상태인가, 얼마나 존재하는가?

구조 번호·recycle 순서로 전환 시간이나 속도를 읽지 않는다.

휴식 · 10분

10분 뒤 실습을 시작합니다.
활동지와 practice/ 파일을 준비합니다.

실습의 목표와 파일

활동지: 진화 관계·정렬·비교 결과 해석

practice/: GPU 없이 A3M을 읽고 수정

examples/: 실제 단백질로 예측하는 선택 시연

가상 실습 자료와 실제 예측 결과를 구분

실습 1 · 중복 사건으로 관계 판단

종이·구두 응답 또는 컴퓨터 실습

조상 유전자가 먼저 A·B로 중복되었습니다.

이후 종분화로 사람·생쥐 계통이 갈라졌습니다.

사람 A-생쥐 A, 사람 A-생쥐 B의 관계는?

종 안에서만 paralog가 생기는지 설명하세요.

실습 2 · A3M을 열로 읽기

종이·구두 응답 또는 컴퓨터 실습

practice/fictional_learning.a3m에서 query와 homolog 행을 찾으세요.

소문자를 제외한 정렬 열 수를 세어 보세요.

gap과 X가 의미하는 차이를 적으세요.

행 수를 줄이면 어떤 정보가 함께 줄어들까요?

실습 3 · 입력을 바꾸고 확인

종이·구두 응답 또는 컴퓨터 실습

practice/run_practice.sh 또는 README의 Python 명령 실행

Depth 조건과 group A/B 조건을 비교

Homolog의 지정 열만 X로 가리기

각 출력에서 query와 정렬 열 수를 다시 확인

ColabFold 노트북으로 실제 예측

1. examples/calmodulin_P0DP23.fasta의 서열 입력
2. 기본 MSA 예측 후 A3M과 결과 파일 저장
3. msa_mode를 custom으로 바꾸고 준비한 A3M 업로드
4. 조건마다 같은 모델·seed 설정으로 실행

ColabFold에서 depth 조건 비교

```
colabfold_batch target.a3m results/depth32 \  
  --model-type alphafold2_ptm --max-msa 32:64 \  
  --num-models 1 --num-seeds 3 --num-recycle 3
```

```
colabfold_batch target.a3m results/depth128 \  
  --model-type alphafold2_ptm --max-msa 128:256 \  
  --num-models 1 --num-seeds 3 --num-recycle 3
```

32:64 = max-seq:max-extra-seq

3개 seed는 반복 비교용 예시

별도 결과 폴더에 보관

설치된 ColabFold와 실제 target.a3m이 필요합니다.

max-msa는 내부의 주 MSA·extra MSA 한도입니다.

Boltz-2에서 같은 A3M 사용

```
python3 examples/prepare_inputs.py \  
    examples/calmodulin_P0DP23.fasta target.a3m \  
    --out prepared
```

```
boltz predict prepared/boltz.yaml \  
    --out_dir results/boltz
```

FASTA와 MSA query 일치 검사

AF3 JSON과 Boltz YAML 생성

실제 추론은 별도 실행

YAML의 protein 항목에 sequence와 msa 경로 지정

examples/prepare_inputs.py로 입력 파일 생성

같은 입력을 사용해 모델 간 차이를 관찰

Chai-1과 ESMFold 비교 경로

실행 경로	입력·확인 사항
chai-lab fold prepared/chai.fasta results/chai	기본 조건의 단일 서열 예측
Chai-1에서 custom MSA 사용	공식 .aligned.pqt 변환 예제
esm-fold -i 입력.fasta -o 결과폴더	설치된 ESMFold 환경 필요

- Chai-1: 전용 FASTA 형식으로 입력
- MSA 사용 시 공식 변환·서버 옵션 확인
- ESMFold: 별도의 입력 MSA 없이 예측
- 모델 변화와 MSA 변화의 효과를 따로 기록

예측 구조 비교의 기준

1강에서 사용한 뷰어로 구조와 confidence 파일 열기
동일한 서열 구간과 원자를 정렬해 비교
도메인 각도·접촉·거리처럼 질문에 맞는 특징 측정
긴 loop 하나가 전체 RMSD를 키웠는지 확인

실습 4 · 대안 구조 후보 선택

후보	평균 pLDDT	구간 간 PAE	C α 거리
F1	91	3.1 Å	8.2 Å
S1	88	4.4 Å	16.4 Å
S2	50	18.0 Å	22.0 Å
F2	92	3.0 Å	8.6 Å

가상 180잔기 표적의 사고 실험이며 실제 예측이 아닙니다.

거리: 40–140번 C α / PAE: 두 지정 구간 사이 평균

최종 설명 활동

종이·구두 응답 또는 컴퓨터 실습

“두 유전자는 다른 종에 있으니 ortholog다.”

“MSA cluster가 3개이므로 구조 상태도 3개다.”

“예측 100개 중 20개가 열렸으니 점유율은 20%다.”

각 주장에 빠진 근거를 한 문장씩 적으세요.

오늘 배운 내용

진화 관계는 공통조상에서 일어난 사건으로 판단

MSA는 진화적 대응을 가정한 정렬

MSA 조작은 서로 다른 구조 가설을 탐색하는 도구

후보 구조는 신뢰도·재현성·실험 근거로 평가

논문과 실행 문서

Jumper et al. (2021), Highly accurate protein structure prediction with AlphaFold

<https://www.nature.com/articles/s41586-021-03819-2>

Abramson et al. (2024), Accurate structure prediction of biomolecular interactions with AlphaFold 3

<https://www.nature.com/articles/s41586-024-07487-w>

ColabFold official repository

<https://github.com/sokrypton/ColabFold>

Boltz official prediction documentation

<https://github.com/jwohlwend/boltz/blob/main/docs/prediction.md>

Chai-1 official repository

<https://github.com/chaidiscovery/chai-lab>

전체 출처와 논문 그림 라이선스: content/sources.json 및 발표자 노트