

MSA와 단백질 구조 예측

진화 관계와 대안 구조 탐색

먼저 MSA가 AlphaFold에 주는 정보와 중요한 이유를 이해하기

진화 관계·coevolution → MSA 조작 → 구조와 신뢰도 읽기

개념 설명 직후 짧은 실습 · 휴식 포함 3시간

AlphaFold에서 MSA는 어디에 쓰일까?

순서	정보의 흐름
① Query 입력	구조를 알고 싶은 단백질의 아미노산 서열
② 검색·정렬	상동 서열 검색 → 다중서열정렬(MSA)
③ 모델의 추론	Query·MSA·선택적 template → 잔기 사이 관계 추론
④ 구조 출력	원자 좌표 + 예측 신뢰도(pLDDT·PAE)

MSA = Multiple Sequence Alignment · 관련 서열의 대응 위치를 나란히 정렬

MSA는 이미 학습된 모델이 예측할 때 읽는 입력입니다.

AF2/ColabFold의 흐름입니다. AF3도 MSA를 쓰지만 내부 처리 방식은 다릅니다.

서열 한 줄에서는 보이지 않던 단서가 생긴다

position	1	2	3	4	5	6	7	8
query	A	C	D	G	F	K	L	M
homolog1	A	C	E	G	Y	R	I	M
homolog2	V	C	K	A	F	D	L	M
homolog3	V	C	R	A	Y	E	I	M

교육용 가상 MSA · position: 정렬 위치 / 행: 관련 서열 하나 / 열: 대응 위치

2열 C·8열 M: 여러 서열에서 유지되는 위치 → 보존(conservation)

3·6열: D/K, E/R, K/D, R/E로 조합이 함께 달라짐 → 공변화

공진화 패턴은 3차원에서 가까운 잔기 쌍을 추정하는 단서입니다. 다음 그림으로 연결합니다.

공진화가 3차원 구조 정보를 주는 이유


MSA · 함께 달라지는 두 열

	i = 20		j = 80
query	D	...	K
homolog1	E	...	R
homolog2	K	...	D
homolog3	R	...	E

→
학습된 모델이
위치 사이 관계 추론

서로 맞는 잔기 조합이
여러 상동 서열에 남을 수 있음

구조 · 공간상 근접 후보



서열에서 60칸 떨어진 위치도
접하면 가까워질 수 있음

접촉을 유지하는 선택이 잔기 조합을 연결할 수 있으므로, MSA의 공진화 신호는 3차원 배치의 단서가 됩니다.

개념도·가상 예시: 100잔기 중 20·80열만 발췌. 점선은 추론할 후보 관계이며 실제 예측 좌표가 아닙니다.

Homology: 얼마나 닮았나보다 어디에서 왔나

용어	무엇을 말하나
Homology	공통 조상에서 유래한 관계
Identity	정렬에서 같은 잔기의 비율
Similarity	정의한 점수 체계에서 유사한 잔기 관계

상동성(homology)은 공통 조상에서 유래했다는 관계

“70% homology” 대신 “정의한 정렬에서 70% identity”라고 표현

Ortholog와 paralog: 갈라진 사건을 묻는다

관계	기준 사건	기억할 점
Ortholog	종 분화(Speciation, S)	기능 동일성을 보장하지 않음
Paralog	유전자 중복(Duplication, D)	같은 종 또는 다른 종에 존재


두 유전자의 가장 최근 공통 조상에서 일어난 사건을 확인

종 이름·서열 유사도·기능의 같고 다름만으로 정하지 않음


Species tree와 gene tree는 다른 질문

교육용 가상 예시

Species tree



Gene tree



S = 종 분화, D = 유전자 중복


A와 B는 종 이름; A_g1 등은 유전자 이름

Species tree: 종들의 분기 관계

Gene tree: 특정 유전자 가족의 계보와 중복·소실

예제 1: 종 분화보다 먼저 중복되었다면

교육용 가상 계통수: 중복 → 종 분화



D에서 1번·2번 유전자 계열이 먼저 나뉨


두 S는 같은 A-B 종 분화를 각 유전자 계열에서 표시

A_1-B_1은 ortholog; A_1-A_2와 A_1-B_2는 paralog

같은 종 안의 관계와 다른 종 사이의 관계를 모두 확인

예제 2: 종 분화 뒤에 중복되었다면

교육용 가상 계통수: 종 분화 → 중복



A 계통에만 중복이 생긴 경우

A_1-B_1과 A_2-B_1은 각각 orthology 관계

A_1과 A_2는 서로 paralog

A_1과 A_2는 각각 B_1의 ortholog: B_1에 대한 co-orthologs

Paralog는 종 안에도, 종 사이에도 있다

관찰 또는 용어	해석 기준
Within-species paralog	같은 종의 두 유전자; 조상 중복 시점은 별도 확인
Between-species paralog	다른 종의 두 유전자; 공통 조상 노드는 D
Inparalog / outparalog	기준 종 분화 뒤 / 앞의 중복에서 유래

“같은 종이면 paralog, 다른 종이면 ortholog”는 불완전한 규칙

In-/out-paralog는 비교하는 종 분화 시점에 대한 상대적 용어

유전자 소실: 남은 하나끼리 비교하면 생기는 착시

교육용 가상 계통수: 중복 뒤 서로 다른 사본 소실



현재 관찰되는 유전자는 A_1과 B_2

현재 사본 수와 과거 분기 사건을 구분


각 종에 한 개씩 남았어도 일대일 ortholog라는 보장은 없음

다른 종의 서열·유전자 계통수·주변 유전자 정보가 판별에 도움


활동지 1 · 두 계통수에서 진화 관계 판정

상황 A: $D \rightarrow S$ / 상황 B: $S \rightarrow D$

A: duplication $\rightarrow$ speciation



B: speciation $\rightarrow$ duplication



문제 · 근거와 함께 답하세요

① 상황 A: H_A-M_A , H_A-H_B , H_A-M_B 의 관계와 분기 사건은?

② 상황 B: $H1-H2$, $H1-M$, $H2-M$ 의 관계는? M 에 대한 $H1-H2$ 의 관계는?

③ 가장 비슷한 두 서열은 반드시 ortholog일까요? 빠진 정보는?

H=사람 계통, M=생쥐 계통. 가상 이력이며 가지 길이는 시간·유사도를 뜻하지 않습니다.

정답·해설 · 상황 A: 중복 뒤 종분화

비교할 유전자 쌍	처음 만나는 사건	관계
H_A-M_A	종분화 S	Ortholog
H_A-H_B	중복 D	Paralog
H_A-M_B	중복 D	Paralog

두 유전자에서 조상 쪽으로 거슬러 올라가 처음 만나는 노드를 찾습니다. 그 사건이 S인지 D인지로 판정합니다.

H_A-M_B는 서로 다른 종에 있어도 paralog입니다. 종 이름이나 서열 유사도만으로 관계를 정하지 않습니다.

정답·해설 · 상황 B와 서열 유사도의 한계

상황 B의 비교	처음 만나는 사건	관계
H1-H2	중복 D	Paralog
H1-M / H2-M	종분화 S	두 쌍 모두 ortholog

H1-H2는 M에 대한 co-orthologs입니다. H1과 H2 서로의 관계는 paralog입니다.

③ 높은 identity만으로 orthology를 확정할 수 없습니다. 유전자·종 계통수와 중복·종분화·소실 이력에 대한 근거가 필요합니다.

Ortholog여도 기능이 완전히 같지는 않다

알 수 있는 것	추가 확인할 것
Orthology / paralogy	기원과 분기 사건
높은 서열 동일성	정렬 길이·도메인 구성·진화 관계
비슷한 예측 구조	기질·활성·발현·실험 조건

진화 관계는 기능 추론의 근거이며 기능 실험의 대체물이 아님

최고 유사도 hit 하나만으로 orthology 또는 기능을 확정하지 않음

유전자 가족에서 MSA로: 대응 위치를 제안한다

Multiple sequence alignment(MSA): 여러 상동 서열의 대응 위치를 정렬
정렬은 비교를 위한 가설이며 모든 열이 정확하다는 보장은 없음
너무 먼 서열·부분 서열·다른 도메인 구성은 별도 점검

MSA 읽기: 행·열·query·gap

교육용 가상 서열: 실제 단백질 아님

정렬 열	123456789
query	AC-DEFGHI
seq_A	ACQDEYGHI
seq_B	AC-NEFG-I
seq_C	AS-DEF-HI

4행 × 9열; query의 실제 길이는 8잔기

3열의 Q는 query에 대응 잔기가 없는 삽입 위치

행(row)은 서열, 열(column)은 대응 위치, “-”는 gap

Query는 이번 분석의 기준 서열; 항상 조상 서열이라는 뜻은 아님

Gap 하나가 잔기 번호를 바꾼다

교육용 가상 서열

정렬 열	1	2	3	4	5	6	7	8	9
query	A	C	-	D	E	F	G	H	I
query 잔기	1	2	-	3	4	5	6	7	8

정렬 4열 = query의 D3

원래 query 서열: ACDEFGHI

정렬 열 번호와 query 잔기 번호를 구분해서 기록

Gap만으로 삽입·결실의 진화 방향을 확정할 수 없음

FASTA: 이름 줄과 서열 줄부터 읽기

```
>query_synthetic    educational example  
ACDEFGHI  
>seq_A_synthetic    educational example  
ACQDEYGHI
```

두 서열의 실제 길이는 8과 9

이 텍스트는 정렬 전의 교육용 가상 FASTA

“>”로 시작하는 줄은 이름·설명, 다음 줄은 서열

여러 FASTA 서열이 있다고 자동으로 MSA가 되는 것은 아님

A3M: 대문자와 소문자는 서로 다른 역할

교육용 가상 A3M

```
>query
```

```
ACDEFGHI
```

```
>seq_A
```

```
ACqDEYGH I
```

```
>seq_B
```

```
ACNEFG-I
```

seq_A: q는 삽입, Y는 대응 열의 치환

겉보기 문자 수가 달라도 같은 match 열을 표현 가능

대문자 = match 상태의 잔기; 소문자 = 삽입 잔기; “-” = 결실 표시

Match는 query와 같은 아미노산이라는 뜻이 아님

활동지 2 · 전체 A3M을 읽고 답하기

실습용 A3M · 전체 입력

```
>query
ACDEFGHIKLMN
>example_A1 group=A
ACDEFGHIKLMN
>example_A2 group=A
ACDeeEFGHIKLMN
>example_A3 group=A
ACDE-GHIKLMN
>example_B1 group=B
ACDEYGHIKLXN
>example_B2 group=B
ACDttEYGHIKL-N
>example_B3 group=B
AC-EYGHIKLXN
```

문제 · 근거와 함께 답하세요

- ① Query 포함/제외 행 수와 정렬 열 수는?
- ② ee의 위치는? 대문자화하면 생기는 오류는?
- ③ A3의 gap·B1의 X: 열 번호와 뜻은?
- ④ 행을 복제하면 독립 진화 정보도 늘어나나요?

허구 자료이며 실제 예측 표적이 아닙니다. A/B는 임의 라벨입니다. 헤더 설명은 축약했고 서열은 그대로입니다.

정답·해설 · 활동지 2쪽 · A3M의 행과 열

세는 대상	계산 또는 확인	정답
Query 행	query 헤더 1개	1행
Homolog 행	$A1 \cdot A2 \cdot A3 + B1 \cdot B2 \cdot B3$	6행
전체 raw depth	query 1 + homolog 6; 동일한 A1도 포함	7행
정렬 열	각 행의 소문자 제외; 대문자·gap 포함	12열

세는 순서: “>” 헤더별 서열 수 → query 구분 → 소문자를 제외한 정렬 열.

흔한 오류: 복제 행 증가 = 정보 증가. 다양성·coverage·정의를 기록한 Neff도 확인.

정답·해설 · 활동지 2쪽 · ee, gap, X의 차이

교육용 가상	A3M 발취
정렬 열	123456789012
query	ACDEFGHIKLMN
A2 원문	ACDeeEFGHIKLMN
A2 열 대응	ACDEFGHIKLMN
A3	ACDE-GHIKLMN
B1	ACDEYGHIXLXN

ee = D(3열) 뒤, E(4열) 직전 삽입; 원문 14글자 / 정렬 12열

“A2 열 대응”은 소문자를 제외해 읽는 보조 표시; 원본 편집 지시가 아님

A3의 5열 “-”는 대응 잔기가 없는 gap; B1의 11열 X는 잔기 정체 미상·가림.

흔한 오류: ee를 대문자화해 2열 추가, 또는 X를 gap으로 바꾸기.

Coverage와 identity: 분모를 함께 적는다

교육용 정의	계산
Query coverage	짜지어진 query 잔기 수 / query 길이
Identity	같은 잔기 수 / 양쪽에 잔기가 있는 비교 위치 수
보고 예	identity 80%, coverage 25%; 각 분모도 기록

Coverage: query의 어느 정도를 비교했는가?

Identity: 비교한 위치 중 어느 정도가 같은 잔기인가?

바로 실습 · Coverage와 identity 계산

교육용 가상 서열

query ACDEFGHI

A ACDE----

B ACNEYGHI

A의 끝부분 gap은 query 위치를 덮지 않음

Coverage와 identity의 분모를 각각 적기

Query 길이 8; A와 B 각각 coverage와 identity를 계산

분모는 앞 장의 교육용 정의를 사용

전체 query를 설명할 때 어떤 차이를 함께 보고해야 하는가?

정답·해설 · Coverage와 identity · 분모부터 쓰기

가상 hit	Coverage: 짝지어진 수 / 8	Identity: 동일 수 / 비교 수
A: ACDE----	$4/8 = 50\%$	$4/4 = 100\%$
B: ACNEYGHI	$8/8 = 100\%$	$6/8 = 75\%$
차이의 근거	A: 뒤 4곳 gap; B: gap 없음	A: 4곳 동일; B: D/N·F/Y 다름

계산 순서: 짝지어진 위치 수 → 같은 잔기 수 → 지표별 분모에 대입.

흔한 오류: A의 identity를 4/8로 계산. 여기서는 gap 없는 비교 4곳이 분모.

Conservation: 한 열에서 무엇이 유지되는가?

교육용 가상 서열

seq_1 ACDK

seq_2 ASDK

seq_3 ACEK

seq_4 ASER

열 1234

보존도는 한 열의 잔기 분포에 대한 질문

“모두 같다”와 “서로 독립적인 근거가 많다”를 구분

한 위치의 잔기 분포를 읽는 것이 보존도(conservation)

보존된 위치는 구조·기능 제약의 후보이며 원인은 추가 확인

보존·공변이·공진화는 서로 다른 질문


개념	무엇을 묻는가?	예
Conservation 보존	한 위치에서 어떤 잔기가 유지되는가?	위치 i가 대부분 D
Covariation 공변이	두 위치의 조합이 독립적 분포와 다른가?	i가 D이면 j가 K인 경향
Coevolution 공진화	위치들의 진화가 어떻게 서로 의존하는가?	구조·기능 제약을 함께 만족

이 강의에서는 관찰한 통계 패턴과 그 패턴의 진화적 설명을 구분

Ortholog/paralog는 행 사이의 관계; 잔기 공변이는 열 사이의 관계


접촉을 유지하는 선택이 공진화를 만들 수 있다

상보적 조합 A




반대 전하 조합
이 가정에서는 유리

상보적 조합 B



다른 잔기라도
반대 전하 조합 유지

비상보적 조합



같은 전하 조합
이 가정에서는 덜 유리

한 위치의 변화가 다른 위치의 허용 잔기를 바꿀 수 있다

이런 제약이 상동 서열의 조합 패턴에 남을 수 있어, 진화 정보로 접촉하는 위치 쌍을 추정할 수 있습니다.

개념도·가상 예시. 가까운 두 위치의 반대 전하가 유리하다고 가정. 색=i/j 위치, -/+ = 축색 전하. 진화 순서 아님.

두 열의 빈도와 조합 빈도를 따로 센다

8행의 가상 자료	j = D	j = K	행 합계
i = D	0	4	4
i = K	4	0	4
열 합계	4	4	8

관찰: $P(D_i, K_j) = 4/8 = 1/2$

독립이라면: $P(D_i) \times P(K_j) = 1/2 \times 1/2 = 1/4$

이 가상 자료에는 통계적 의존성이 있음; 그 원인은 아직 모름

활동지 3 · 두 열의 공동 빈도 계산

가상 조합	자료 P: 8행	대조 자료 Q: 8행
D-D	0	2
D-K	4	2
K-D	4	2
K-K	0	2

D=Asp, K=Lys; i,j는 같은 단백질의 두 정렬 위치입니다. 두 자료는 가상입니다.

① 각 자료의 $P(D_i)$, $P(K_j)$, $P(D_i, K_j)$ 를 계산하고 독립일 때의 곱과 비교하세요.

단일 열의 빈도·보존도만으로 두 자료를 구별할 수 있나요?

정답·해설 · 같은 보존도, 다른 공동 분포

계산·판정	자료 P	대조 자료 Q
한 열씩 센 주변 빈도	$P(D_i) = 4/8 = 1/2$ $P(K_j) = 4/8 = 1/2$	$P(D_i) = 4/8 = 1/2$ $P(K_j) = 4/8 = 1/2$
함께 나타난 D-K 빈도	$P(D_i, K_j) = 4/8 = 1/2$	$P(D_i, K_j) = 2/8 = 1/4$
독립일 때 기대 빈도	$(1/2) \times (1/2) = 1/4$	$(1/2) \times (1/2) = 1/4$
경험적 분포의 판정	관찰 $1/2 \neq$ 기대 $1/4$ 두 열이 독립적이지 않음	네 조합이 모두 각각 $1/4$ 이 표의 두 열은 독립

한 열의 빈도·보존도는 같으므로 구별 불가. 두 열의 조합까지 보아야 합니다.

계통·간접 연관도 공변이를 만듭니다. 이 계산만으로 직접 접촉을 입증하지는 못합니다.

휴식 · 10분

10분 뒤 다시 시작합니다.

다음: 공변화 패턴을 유전자 계통과 함께 해석하기

Ortholog를 모아도 공통 조상은 남아 있다

질문	Ortholog를 모으면?
다른 중복 계열의 혼합인가?	대상 계열을 맞추는 데 도움이 됨
각 서열은 독립 관측인가?	아님: 가까운 종은 조상의 패턴을 공유
모든 위치가 같은 제약을 받나?	보장 없음: 계통별 기능·환경 차이도 가능

Ortholog 관계는 비교할 유전자 계열을 정리하는 데 도움

후손 100개의 같은 조합 ≠ 독립적인 보상 치환 100회

계통수의 여러 가지에서 반복되었는지는 따로 평가해야 함

Paralog 혼합은 계열 차이를 함께 섞는다

같은 MSA를 보는 방법	확인할 것
모든 상동 서열을 합침	관찰한 조합이 하위 계열 이름을 구별하는가?
중복 계열별로 나눔	각 계열 안에도 두 위치의 변화가 있는가?
계열을 제외함	혼합 효과와 함께 유용한 다양성도 잃는가?

두 하위 계열이 각각 다른 잔기를 선호하면 혼합 후 공변이가 생길 수 있음

Ortholog만 남기는 규칙 대신 분석 목적·정렬·계열 구성을 함께 점검

활동지 3 · 계열을 나누고 진화 이력 해석

가상 서열: 각 이름이 한 행	i	j
A_H, A_M, A_R, A_F	모두 D	모두 K
B_H, B_M, B_R, B_F	모두 K	모두 D

가정: A/B 중복 → H/M/R/F 네 종 분화. 추가 중복·소실 없음. D=Asp, K=Lys.

② A_H-A_M, A_H-B_M의 관계는? 각 계열 내부에 변이가 남나요?

③ 8행은 독립 보상 변화 8회 또는 직접 접촉의 증거인가요? 공통 조상 효과는?

④ Ortholog만 모으면 계통 효과가 사라지나요? 더 필요한 근거를 쓰세요.

정답·해설 · 계열 차이와 공진화를 구분

비교	정답·관찰	판정 근거
A_H-A_M	Ortholog	최근 공통 조상에서 종 분화(S)
A_H-B_H A_H-B_M	모두 paralog	최근 공통 조상에서 중복(D)
각 계열 내부	A: D-K만 / B: K-D만	변이가 없어 내부 공진화의 근거를 평가하기 어려움
합친 8행	D-K 4행 / K-D 4행	공변이 패턴이 A/B 구분과 겹침

8행은 독립 보상 변화 8회가 아닙니다. 조상의 조합을 물려받았을 수 있어 직접 접촉도 확인할 수 없습니다.

④ Ortholog 사이에도 공통 조상 효과가 남습니다. 정렬·계통수·계열 내부 변이·독립 가지의 변화와 구조·실험 근거를 함께 확인합니다.

복합체에서는 어떤 서열끼리 짝지었는가?

분석	한 행의 의미	핵심 확인
단백질 내부	한 상동 단백질의 서열	같은 서열의 위치 i와 j
단백질 사이	단백질 P 서열 Q 서열	P의 위치 i와 Q의 위치 j
같은 종에 여러 paralog	P1/P2와 Q1/Q2 존재	P1의 상대가 Q1인가 Q2인가?

Paired MSA는 서로 다른 단백질의 서열을 같은 행에 대응시킴

같은 종에 있다는 사실만으로 실제 결합 파트너를 확정할 수 없음

함께 변한다고 모두 직접 연결된 것은 아니다

접근	무엇을 하는가?
공변이·MI	두 열의 관찰 분포가 독립적인지 비교
DCA	여러 열을 함께 모형화해 직접·간접 통계 효과를 구분
AlphaFold	학습한 모형으로 서열·MSA 등 정보를 통합해 구조 예측

$i-k$ 와 $k-j$ 관계만 있어도 $i-j$ 에 간접 상관이 생길 수 있음

추정한 coupling도 실제 접촉·작동 기전의 자동 증명이 아님

Raw depth와 Neff: 행 수와 다양성은 다르다

교육용 재가중 예	Raw depth	가중치 합
완전히 동일한 서열 100개	100	$100 \times 1/100 = 1$
서로 기준 이상 유사한 쌍이 없는 100개	100	$100 \times 1 = 100$
실제 MSA	행 수를 기록	정의·유사도 기준·coverage도 기록

Raw depth는 서열 행 수; 같은 서열이 많아도 그대로 증가

Neff는 중복·유사도를 반영하는 지표이며 계산법을 반드시 명시

AlphaFold2와 AlphaFold3

항목	AlphaFold2 계열	AlphaFold3
주요 입력	단백질 서열·MSA·template	단백질·핵산·리간드 등
좌표 생성	구조 모듈과 recycling	Diffusion 기반 생성
이 강의에서 역할	MSA 조작의 주요 실습 도구	기본 예측과 확장 적용 비교
해석 원칙	여러 예측을 만들고 검증	별도 검증 후 기법 적용

이 강의의 MSA 조작 사례는 주로 AF2에서 검증되었습니다.

웹 서버와 로컬 실행

웹 서버: 서열과 분자를 입력해 빠르게 시작

로컬 AF3: JSON으로 custom MSA-template 지정

MSA 조작 실습: custom A3M을 받는 ColabFold 활용

실제 예측에는 모델 설치·계산 자원이 필요

Custom MSA의 기본 조건

첫 번째 서열은 예측할 query와 일치

정렬 열은 query의 위치와 대응

A3M의 소문자는 insertion, 대문자·gap은 정렬 열
비교할 때 query·template·모델 버전을 함께 기록

ColabFold 1 · 접속과 실습 준비

아래 URL을 브라우저 주소창에 붙여 넣고 Google 계정으로 로그인
필요하면 File → Save a copy in Drive로 개인 사본 저장
예제 파일: examples/calmodulin_P0DP23.fasta · 다운로드는 46번
이 수업에서는 단백질 한 사슬, 149개 아미노산을 입력

<https://colab.research.google.com/github/sokrypton/ColabFold/blob/main/AlphaFold2.ipynb>

ColabFold 2 · GPU와 노트북 실행 방식

Runtime → Change runtime type → GPU 선택 → Save

한국어 메뉴: 런타임 → 런타임 유형 변경

코드 셀은 왼쪽 ▶로 실행하며, 위에서 아래로 이어집니다.

GPU를 할당받지 못하면 교사 결과·오프라인 활동으로 진행

ColabFold 3 · 서열과 기본 조건 입력

화면 항목	이번 실습의 입력	의미
query_sequence	Human CALM1 · 149 aa	예측할 단백질
jobname	calm_baseline	결과를 구분할 이름
num_relax / template_mode	0 / none	처음에는 template 없이
msa_mode	mmseqs2_uniref_env	검색으로 기본 MSA 생성

FASTA 다운로드: 아래 URL → calmodulin_P0DP23.fasta로 저장

제목(>) 줄 제외 → query_sequence에 서열만 입력 → length 149 확인

<https://rest.uniprot.org/uniprotkb/P0DP23.fasta>

ColabFold 4 · Run all과 계산 진행 확인

Advanced settings: model_type=alphafold2_ptm, num_recycles=3

Sample settings: max_msa=auto, num_seeds=1, use_dropout 해제

Runtime → Run all / 런타임 → 모두 실행

설치 → MSA 검색 → Run Prediction → 결과 표시 순서 확인

ColabFold 5 · 결과와 MSA 다운로드

Display 3D structure에서 rank_num과 잔기별 색 확인

Plots에서 MSA coverage·pLDDT·PAE 확인

Package and download results의 실행 버튼으로 결과 ZIP 저장

ZIP의 .a3m·구조 .pdb·설정/로그를 함께 보관

실습 확인·해설 · ColabFold 기본 실행

확인할 것	기대되는 상태	이유·오류 확인
서열 입력	Header를 뺀 CALM1 서열, length 149	다른 길이면 제목·다른 서열·중복 붙여넣기부터 확인
설정 확인	jobname=calm_baseline, 지정 모델·template 조건	ZIP의 설정·로그와 입력을 함께 보관해야 재현 가능
파일 확인	다운로드 ZIP에 .a3m·.pdb·설정/로그	MSA 생성·예측·다운로드가 어디까지 끝났는지 확인
그림 읽기	pLDDT·PAE·MSA coverage를 각각 찾기	각 지표의 의미는 다음 설명에서 확인

예측 좌표와 점수에는 고정 정답이 없습니다. seed·GPU·서버·버전에 따라 결과가 달라질 수 있습니다.

GPU 대기로 완료되지 않았다면 성공으로 기록하지 말고 마지막 실행 단계와 오류를 기록합니다.

IDDT · 기준 구조의 주변 거리가 얼마나 보존되었나?

IDDT = local Distance Difference Test · 기준 구조와 비교하는 정확도 점수
원 지표는 원자 단위 평가. 여기서는 AF2의 잔기별 IDDT-C α 를 사용

① 기준 구조에서 중심 C α 의 15 Å 미만 이웃을 선택

② 거리 오차 |예측 거리 - 기준 거리|를 0.5·1·2·4 Å로 검사

전체 구조를 겹칠 필요는 없지만, 대응 잔기와 기준 좌표는 필요

바로 실습 · 네 거리쌍의 IDDT 계산하기

중심 잔기 i와 네 이웃

이 웃	기준 거리 Å	예측 거리 Å	절대 오차 Å	통과 수 / 4
a	4.0	4.2	_____	_____
b	7.0	7.8	_____	_____
c	10.0	11.5	_____	_____
d	14.0	17.0	_____	_____

문제 · 근거와 함께 답하세요

- ① 각 쌍의 |예측 거리 - 기준 거리|를 구하세요.
- ② 오차 < 0.5, < 1, < 2, < 4 Å를 각각 검사해 통과 수를 채우세요.
- ③ $IDDT_i = \text{통과 수 합} / 16 = \underline{\hspace{1cm}}$.
100점 척도로는 _____입니다.

가상 거리 네 쌍. 기준 거리는 모두 15 Å 미만이며, 좌표는 모두 있다고 가정합니다.

정답·해설 · 네 이웃의 거리 오차를 네 번 채점

이웃	기준 거리 (Å)	예측 거리 (Å)	절대 오차 (Å)	통과 수 / 4
a	4.0	4.2	0.2	4 / 4
b	7.0	7.8	0.8	3 / 4
c	10.0	11.5	1.5	2 / 4
d	14.0	17.0	3.0	1 / 4

중심 잔기 i의 가상 이웃 4개만 사용. 오차 < 0.5, < 1, < 2, < 4 Å를 각각 검사

오차 0.8 Å는 1·2·4 Å 검사를 통과합니다. 네 검사는 겹칩니다.

$$IDDT_i = (4 + 3 + 2 + 1) / (4 \times 4) = 0.625 \rightarrow 100\text{점 척도로 } 62.5$$

바로 실습 · 예측 거리가 더 멀어지면?

d의 예측 거리만 19 Å로 변경

이 웃	기준 거리 Å	예측 거리 Å	절대 오차 Å	통과 수 / 4
a	4.0	4.2	0.2	4
b	7.0	7.8	0.8	3
c	10.0	11.5	1.5	2
d	14.0	19.0	_____	_____

문제 · 근거와 함께 답하세요

- ① d의 절대 거리 오차와 네 검사 중 통과 수는?
- ② d는 이웃 계산에 [포함 / 제외]되나요? 어느 거리를 기준으로 판단하나요?
- ③ 새 IDDT_i는 [9/16 또는 9/12]인가요? 100점 척도로는 _____입니다.

오차 < 0.5, < 1, < 2, < 4 Å로 검사합니다. a·b·c와 기준 거리는 바꾸지 않았습니다.

정답·해설 · 오차가 커져도 이웃은 그대로

이웃	절대 오차 (Å)	통과한 기준: 오차 < ... Å	통과 수
a	$ 4.2 - 4 = 0.2$	$0.5 \cdot 1 \cdot 2 \cdot 4$	4
b	$ 7.8 - 7 = 0.8$	$1 \cdot 2 \cdot 4$	3
c	$ 11.5 - 10 = 1.5$	$2 \cdot 4$	2
d	$ 19 - 14 = 5$	없음: 4 Å 기준도 실패	0

새 IDDT_i = $(4 + 3 + 2 + 0) / (4\text{쌍} \times 4\text{기준}) = 9/16 = 0.5625 \rightarrow 56.25\text{점}$

d의 기준 거리 14 Å는 15 Å 미만: 계속 포함합니다. 빼면 분모가 줄어 점수가 부풀려집니다.

pLDDT가 나온 과정 · 채점한 IDDT를 학습 정답으로

AF2 학습 단계	사용 정보	만드는 것
① 구조 예측	서열·MSA 등	예측 좌표 + 잔기별 내부 표현
② 정답 점수 계산	예측 좌표 + 학습용 기준 좌표	실제 계산한 잔기별 IDDT- $C\alpha$
③ 신뢰도 학습	내부 표현 → 신뢰도 head	IDDT의 50개 구간에 대한 분포

예: 계산한 IDDT 0.625 → [0.62, 0.64) 구간이 학습 정답

예측 분포가 정답 구간을 맞히도록 학습합니다(cross-entropy).

기준 좌표는 채점·지도에 사용하며, 신뢰도 head에 정답으로 입력하지 않습니다.

바로 실습 · IDDT 계산과 pLDDT 추론 구별하기

세 구간의 확률가중 평균

구간 중심 c	확률 p	$p \times c$
0.49	0.10	_____
0.69	0.20	_____
0.89	0.70	_____

문제 · 근거와 함께 답하세요

- ① IDDT를 직접 계산할 때와 pLDDT를 추론할 때, 어느 쪽에 기준 구조가 필요한가요?
- ② pLDDT 90은 좌표가 정확할 확률 90% 또는 상태의 점유율 90%인가요?
- ③ $100 \times \sum(p \times c) = \underline{\hspace{2cm}}$. 최다 확률 구간의 중심 $\times 100$ 과 같은가요?

AF2의 50개 중심 중 세 개를 사용한 가상 근사입니다. 나머지 확률은 0으로 단순화했습니다.

정답·해설 · 기준 구조와 확률가중 평균 구별하기

구간 중심 c_k	예측 확률 p_{ik}	$p_{ik} \times c_k$
0.49	0.10	0.049
0.69	0.20	0.138
0.89	0.70	0.623

- ① 기준 구조: IDDT 직접 계산에는 필요 / 학습된 pLDDT 추론에는 불필요
- ② pLDDT 90은 좌표가 정확할 확률 90%·상태 점유율 90%가 아닙니다.
- ③ 50 logits → softmax → $100 \times \sum(p \times c) = 81$; 최다 확률 구간만 고르면 89


pLDDT의 네 가지 색 · 숫자와 함께 읽기

점수 범위	보통의 표시색	해석의 출발점
$90 \leq \text{점수} \leq 100$	진한 파랑	매우 높은 국소 신뢰도
$70 \leq \text{점수} < 90$	하늘색	대체로 믿을 만한 골격
$50 \leq \text{점수} < 70$	노랑	낮은 신뢰도, 세부 해석 주의
$0 \leq \text{점수} < 50$	주황	매우 낮음, 좌표 해석을 보류

색은 신뢰도를 쉽게 보기 위한 표시입니다. 화면의 범례를 확인하세요.

구간 경계는 해석 지침이며, 특정 값에서 정확도가 갑자기 바뀌지 않습니다.

평균 82.8점이 가리는 낮은 신뢰도 구간



가상 개념도(실제 예측 아님): A 1-5 / 연결부 6-7 / B 8-12

전체 평균 82.8 / A·B 각각 91.2 / 연결부 41.0

평균과 함께 잔기별 그래프·3D 색·관심 부위를 확인

바로 실습 · pLDDT 그래프에서 말할 수 있는 것

가상 잔기별 pLDDT (0–100)

구간	위치	각 위치의 pLDDT
A	1–5	94, 93, 91, 90, 88
연결부	6–7	43, 39
B	8–12	86, 92, 94, 93, 91

문제 · 근거와 함께 답하세요

- ① 특히 조심해서 해석할 위치 두 곳과 점수를 쓰세요.
- ② 전체 평균 82.8이면 모든 위치를 믿을 수 있나요?
- ③ A와 B의 상대 방향까지 확정할 수 있나요?
- ④ 낮은 값만으로 무질서·빠른 운동을 확정할 수 있나요?

도메인 개념을 12개 위치로 축약한 가상 자료. 실제 단백질·추론 결과가 아니며 A3M 예제와 별개입니다.

정답·해설 · 평균으로 낮은 신뢰도 구간을 가리지 않기

질문	정답	왜 그렇게 해석하나요?
특히 주의할 위치	6번 43 · 7번 39	연결부의 국소 신뢰도가 낮습니다.
평균 82.8이면 모두 신뢰?	아니요: $994/12 \approx 82.8$	다른 높은 값들이 연결부 평균41.0을 가립니다.
A·B의 상대 방향 확정?	아직 알 수 없습니다.	각 부분의 pLDDT는 도메인 간 배치 점수가 아닙니다.
무질서·빠른 운동 확정? 가능한 설명일 뿐입니다.		정보 부족도 가능하며 운동 속도는 점수로 알 수 없습니다.

A·B 평균은 각각 91.2: 국소 구조를 검토할 근거가 있습니다. 상대 배치는 PAE도 읽어야 합니다.

점수가 같은 두 부분이 같은 모양이라는 뜻은 아닙니다.여기의 숫자는 설명용 가상 점수입니다.

PAE · 기준을 고정하면 다른 위치는 얼마나 불확실할까?

PAE = Predicted Aligned Error, 예측 정렬 오차

PAE(i,j): j의 국소 좌표계를 맞췄다고 할 때 i의 예상 위치 오차

단위 Å, 낮을수록 상대 위치를 더 확신 / 이 예제: 행 i·열 j

두 잔기 사이 거리나 두 실물 구조에서 측정한 RMSD와 다릅니다.

PAE 표 읽기 · 도메인 내부와 도메인 사이

i ↓ / j →	A3	A4	B9	B10
A3	0	1	18	20
A4	1	0	19	21
B9	24	23	0	2
B10	22	24	2	0

가상 예제의 3·4·9·10번만 선택한 4×4 표 / 단위 Å

행 = 평가할 i / 열 = 정렬 기준 j / 도메인 사이 두 방향 모두 확인

교육용 색: 진한 청록 0–2 Å / 옅은색 18–24 Å (낮을수록 더 신뢰)

두 점수 함께 읽기 · 부분의 모양과 상대 배치

높은 pLDDT + 낮은 내부 PAE → 각 도메인 내부 구조를 더 신뢰

높은 도메인 사이 PAE → 두 도메인의 상대 배치는 불확실

유연성·disorder는 가능한 설명이며, 점수만으로 확정하지 않음

낮은 PAE도 실제 결합·상태 점유율·전이 속도를 증명하지 않음

바로 실습 · 같은 pLDDT, 다른 PAE

조건 P의 PAE (Å)

i ↓ / j →	A3	A4	B9	B10
A3	0	1	18	20
A4	1	0	19	21
B9	24	23	0	2
B10	22	24	2	0

문제 · 근거와 함께 답하세요

- ① $PAE(A3, B9) = \text{___} \text{Å}$, $PAE(B9, A3) = \text{___} \text{Å}$. 각 기준은? 잔기 사이 거리인가요?
- ② A/B 내부와 A-B 사이를 비교하세요. 높은 구간별 pLDDT와 큰 구간 간 PAE는 모순인가요?
- ③ Q는 pLDDT가 같고 표의 대각선 밖 PAE가 모두 1–3 Å입니다. 무엇을 더 확신하나요? 결합·상태 존재·점유율도 확정되나요?

전체 12×12 중 3·4·9·10의 가상 부분표. 행 i=평가 대상, 열 j=정렬 기준. A/B 평균 pLDDT는 각각 91.2.

정답·해설 · PAE의 기준과 평가 대상을 나누기

읽은 칸: 행 i·열 j	정렬 기준 j	평가 대상 i	예상 위치 오차
PAE(A3, B9)	B9의 국소 좌표틀	A3	18 Å
PAE(B9, A3)	A3의 국소 좌표틀	B9	24 Å

B9를 기준으로 보면 A3의 예상 오차는 18 Å; A3을 기준으로 보면 B9는 24 Å입니다.

기준 좌표틀이 달라 두 방향 값은 달라도 됩니다. A3-B9 사이의 실제 거리를 읽은 것이 아닙니다.

정답·해설 · Q는 제시된 상대 배치를 더 확신한다

비교할 정보	P	Q	허용되는 해석
pLDDT	원래 점수	P와 동일	국소 신뢰도는 달라지지 않음
내부 PAE: 대각선 밖	1-2 Å	1-3 Å	둘 다 제시된 내부 배치를 확신
A-B 사이 PAE	18-24 Å	1-3 Å	Q가 이 위치쌍의 상대 배치를 더 확신
상태의 실제 비율	제공되지 않음	제공되지 않음	pLDDT·PAE로 점유율을 계산할 수 없음

모순 아님: pLDDT는 국소 모양, PAE는 상대 배치의 신뢰도입니다. 제시한 A-B 배치는 Q가 더 확신합니다.
낮은 PAE로 결합·특정 상태의 존재·점유율을 확정하지 못합니다. 생략한 위치는 별도로 확인합니다.

휴식 · 10분

10분 뒤 다시 시작합니다.

다음: custom MSA와 depth·clustering·masking 실습

ColabFold 6 · Custom MSA 업로드

새 jobname 입력 · query_sequence는 동일하게 유지

MSA options에서 msa_mode를 custom으로 선택

Runtime → Run all → 업로드 창에서 .a3m 한 개 선택

첫 query가 CALM1 149 aa인지 확인하고 결과 ZIP 저장

실습 확인·해설 · Custom MSA 입력

확인할 것	기대되는 상태	이유·오류 확인
Query	원래 CALM1 서열과 첫 query가 일치	길이149만 같아서는 부족: 잔기 서열도 대조
입력 모드	msa_mode=custom, 선택한 .a3m 한 개	다른 조건 파일을 넣었으면 비교 조건이 바뀜
기록	새 jobname·파일명·MSA 행 수·설정	같은 query를 유지하고 무엇을 바꿨는지 명시
결과 확인	새 ZIP에서 구조·점수·설정/로그 확인	구조 변화가 없어도 정상적인 비교 결과

실제 실습에는 CALM1에서 얻은 MSA를 사용합니다. 12열 가상 A3M은 파일 읽기 학습용입니다.

AF3에서 custom MSA 지정

```
"protein": {  
  "id": "A",  
  "sequence": "<full query sequence>",  
  "unpairedMsaPath": "target.a3m",  
  "pairedMsa": "",  
  "templates": []  
}
```

unpairedMsaPath: 직접 준비한 A3M

pairedMsa: 단량체 실습에서는 빈 값

templates: template 비교 조건 고정

아래는 protein 항목의 형식 예시입니다.

실제 FASTA와 A3M을 사용한 완전한 JSON은 [examples/](#)에서 생성합니다.

한 번에 한 조건씩 비교

Baseline: 원본 MSA와 정해진 seed 목록

Depth: 행 수만 줄여 여러 번 표본 추출

Cluster: 비슷한 서열 집단별 입력

Mask: 정해진 열의 정보만 가리는 조건

활동지 4 · 비교 조건을 설계하기

설계	조건 1	조건 2
A	Query Q / template 없음 / 5회	Query Q 일부 삭제 / template 있음 / 50회
B	Query Q / 전체 MSA / 10회	Query Q / 선택 MSA / 10회
B의 공통 조건	모델·template·seed 집합	같이 유지

④ MSA 행 선택의 효과를 보려면 A/B 중 어느 설계가 더 공정한가요?

고정하거나 기록할 항목을 세 가지 이상 쓰고 이유를 설명하세요.

정답·해설 · 공정한 비교는 B

판단	정답과 이유
B를 선택	같은 query·각 10회: homolog 행 선택의 효과를 비교
A의 문제	query 삭제·template 추가·5→50회가 함께 변해 원인 구별 불가
고정할 것	query·모델/가중치·template·예측 seed 집합·recycle·생성 수
기록할 것	선택한 행 ID와 행 수 / 행 추출 seed와 MSA 검색 DB·날짜

전체 MSA 대조군이 있어야 선택 MSA의 변화와 원래 예측 경향을 비교할 수 있습니다.

흔한 오류: seed 개수만 맞추거나, 더 많이 만든 쪽의 최고 점수만 비교하기.

기준 예측부터 기록한다

먼저 고정	변경 후보	함께 기록
Query·모델 버전	MSA 행 또는 열	입력 파일·행 수
Template 조건	Seed·dropout	반복 수·실행 설정
구조 비교 구간	한 조건씩 비교	pLDDT·PAE·구조 차이

같은 단백질의 입력 근거를 바꾸어 비교한다.

Query 서열·길이·번호를 먼저 고정한다.

한 번에 바꾸는 조건과 반복 횟수를 기록한다.

행을 줄인다: MSA subsampling

원래 MSA

query	ACDEFGHI
hom1	AC-EYGHI
hom2	ACDEFG-I
hom3	ACNEFGHI

선택한 MSA

query	ACDEFGHI
hom1	AC-EYGHI
hom3	ACNEFGHI

교육용 가상 정렬. Query 행은 유지하고, homolog 행의 일부를 택한다. 열과 query 길이는 유지한다.

행(row) = 정렬에 포함된 서열 하나

Query는 남기고 homolog 행 일부를 선택한다.

행 수 감소는 정보 감소와 다양성 변화를 함께 만든다.

활동지 4 · Depth를 줄이고 query 확인

원본 MSA와 선택 조건

ID / group	A3M sequence
query	ACDEFGHIKLMN
A1 / A	ACDEFGHIKLMN
A2 / A	ACDeeEFGHIKLMN
A3 / A	ACDE-GHIKLMN
B1 / B	ACDEYGHIXLN
B2 / B	ACDttEYGHIXL-N
B3 / B	AC-EYGHIXLN

```
# depth=4, seed=7
python3 msa_lab.py --depth 4 --seed 7 \
  --out runs/student01
```

문제 · 근거와 함께 답하세요

① Query와 A2·A3·B1만 남깁니다. 첫 행은 무엇이고 왜 유지하나요?

결과의 전체 행 수·homolog 행 수·정렬 열 수는?

원본과 비교해 잃거나 달라질 수 있는 정보는?

실행 위치: Alprediction/practice/ · 컴퓨터 없이도 왼쪽 입력에서 선택 행을 표시해 풀 수 있습니다.

정답·해설 · Query 포함 4행, 정렬 12열

```
depth=4 / row-sampling seed=7
query      ACDEFGHIKLMN
example_A2  ACDeeEFGHIKLMN
example_A3  ACDE-GHIKLMN
example_B1  ACDEYGHIXLXN
```

선택 ID: query, example_A2, example_A3, example_B1


허구 학습 자료: ee는 삽입이므로 A2 원문 14글자, 정렬 12열

원본 7행 → 4행: homolog는 6개에서 3개로 감소하며 query는 불변입니다.

빠진 A1·B2·B3의 정보 때문에 열별 빈도·coverage·조합 빈도가 달라질 수 있습니다.

흔한 오류: depth 4를 homolog 4개로 세기. 4행이 독립 진화 사건 4개라는 뜻도 아닙니다.

논문 그림 읽기: 얇은 MSA의 효과와 한계



점 하나는 예측 구조 하나: 실험 구조와 비교한다.
MSA 깊이에 따라 구조 분포가 달라진 사례가 있다.
다양성 증가에는 잘못 접힌 구조도 섞일 수 있다.

[del Alamo et al., eLife \(2022\), Fig. 1A \(발체\)](#)

[CC BY 4.0](#)

ColabFold 7 · 화면에서 MSA depth 비교

화면 항목	비교 A	비교 B
jobname	calm_depth32	calm_depth64
msa_mode	custom · 동일 A3M	custom · 동일 A3M
max_msa	32:64	64:128
고정 항목	같은 모델·seed 수·template	같은 설정 유지

같은 A3M을 custom으로 재사용하고 max_msa만 변경


두 숫자는 주 MSA·extra MSA 한도이며 총 행 수가 아닙니다.

실습 확인·해설 · max_msa 두 조건 비교

확인할 것	기대되는 상태	이유·오류 확인
공통 입력	같은 CALM1 query와 custom A3M	Query·모델·template·seed 조건도 맞추기
달라지는 값	calm_depth32: 32:64 calm_depth64: 64:128	주 MSA·extra MSA 두 한도만 변경
한도와 실제 행 수	한도96행/192행이라고 합산하지 않기	원본 행 수·중복·전처리 때문에 실제 사용 수는 다를 수 있음
결과 비교	pLDDT·PAE와 같은 원자/구간의 좌표	값이 바뀌거나 구조가 열려야 성공인 것은 아님

두 ZIP과 설정을 보관합니다. 결과 차이가 보이면 동일한 seed 집합으로 반복해 재현성을 확인합니다.

AF-Cluster: 서열을 먼저 나누어 예측



MSA의 homolog를 서열 유사성으로 나눈다.
각 sub-MSA를 별도로 AF2에 입력한다.
KaiB의 알려진 다른 집합을 탐색한 사례가 있다.

[Wayment-Steele et al., Nature \(2024\), Fig. 1d \(발췌\)](#)

각 cluster에도 같은 query가 들어간다

Cluster A 입력

```
>query  
ACDEFGHI  
>hom1  
AC-EYGHI
```

Cluster B 입력

```
>query  
ACDEFGHI  
>hom3  
ACNEFGHI
```

교육용 가상 정렬. 두 입력의 query는 동일하고, 그 아래 homolog 조합만 다르다.

예측 대상 = query, 배경 정보 = homolog 집합

Cluster마다 query를 맨 앞에 다시 넣는다.

Cluster 대표 서열로 query를 바꾸면 대상도 바뀐다.

활동지 4 · 두 그룹의 MSA를 직접 비교

그룹 라벨과 전체 입력

ID / group	A3M sequence
query	ACDEFGHIKLMN
A1 / A	ACDEFGHIKLMN
A2 / A	ACD ee EFGHIKLMN
A3 / A	ACDE-GHIKLMN
B1 / B	ACDEYGH I KLXN
B2 / B	ACD ttt EYGH I KL-N
B3 / B	AC-EYGH I KLXN

문제 · 근거와 함께 답하세요

② 동일 query와 A 행만, 동일 query와 B 행만 각각 묶으세요. 각 파일은 몇 행인가요?

각 그룹의 homolog 5열·11열 분포를 비교하세요.

이 라벨 분리와 AF-Cluster의 차이는? Ortholog 집합·구조 상태라 부를 수 있나요?

A/B는 편의를 위한 사전 라벨입니다. 활동지 3쪽의 진화 이력을 주어진 조건으로 사용하지 않습니다.

정답·해설 · 그룹마다 잔기 분포가 달라진다

파일	포함된 homolog	정렬 5열	정렬 11열
group_A	A1 · A2 · A3	F · F · -	M · M · M
group_B	B1 · B2 · B3	Y · Y · Y	X · - · X

두 파일 모두 동일 query + homolog 3행 = 4행입니다. 표의 분포는 query를 제외했습니다.

허구 header의 A/B 라벨로 분리한 결과입니다. AF-Cluster 알고리즘을 실행한 것이 아닙니다.

A/B를 ortholog 집합이나 열림/닫힘 상태로 부를 근거가 없습니다.

흔한 오류: 같은 행 수면 같은 정보량이라 생각하기. X는 불명 잔기, -는 gap입니다.

서열 cluster는 열역학적 상태가 아니다

분류 질문	사용 정보	바로 알 수 없는 것
어떤 서열이 닮았나?	서열 유사성	구조 상태의 수
어떤 진화 관계인가?	유전자·종 계통	상태별 점유율
어떤 구조가 다른가?	좌표·접촉·실험	전환 속도

서열 유사성은 진화적 관련성과 기능 차이를 섞어 담는다.

Ortholog / paralog 구분과 구조 상태 구분은 다른 문제다.

Cluster 수·크기에서 상태 수·점유율을 바로 읽지 않는다.

2025년 논쟁: 비교 조건을 읽는다

자료	핵심 질문	읽을 때 확인
Nature 비판 (2025)	무작위 표본보다 나은가?	표적·표본 수·AF2 설정
JMB 응답 (2025)	진화 신호를 직접 시험했나?	대조군·추가 분석
우리 비교 설계	무엇 하나가 달랐나?	동일 조건·독립 평가

Matters Arising은 무작위 표본 비교와 해석을 비판했다.

저자 응답은 비교 조건과 진화 신호의 역할을 재검토했다.

강의 결론: 같은 조건의 대조군과 독립 검증이 필요하다.

두 가지 clustering을 구별한다

단계	묶는 대상	목적
AF2 이전	MSA 서열 행	다른 입력 근거 만들기
AF2 이후	예측 구조 후보	중복 정리·대표 선택
실험 검증 이후	관찰된 상태	물리적 해석 뒷받침

입력 clustering: 예측 전에 서열을 묶는다.

출력 clustering: 예측 후 구조를 묶는다.

많은 입력 cluster가 같은 구조를 만들 수도 있다.

열을 가린다: unknown X와 gap의 차이

원래		한 열을 X로 마스킹	
query	ACDEFGHI	query	ACDEFGHI
hom1	AC-EYGHI	hom1	AC-XYGHI
hom2	ACDEFG-I	hom2	ACDXFG-I
	↑		↑

교육용 가상 정렬. X = unknown residue, - = gap. Query 첫 행과 전체 정렬 열 수는 바꾸지 않는다.

열(column) = query의 정렬 위치에 대응

X는 종류를 모르는 잔기, -는 정렬의 gap이다.

오늘 실습에서는 query를 보존한 채 정보만 가린다.

활동지 4 · A2의 5·7·10열을 X로 가리기

수정 전 입력 · 정렬 열은 1부터

query	ACDEFGHIKLMN
A2	ACDeeEFGHIKLMN
A3	ACDE-GHIKLMN

query col 123456789012

mask cols: 5, 7, 10

A2 output: _____

문제 · 근거와 함께 답하세요

③ A2의 정렬 5·7·10열을 X로 바꾼 원문 문자열을 쓰세요.

Query·소문자 ee·A3의 기존 gap은 어떻게 하나요?

어느 열의 빈도와 다른 열과의 조합 정보가 가려지나요?

5·7·10은 원문 문자 위치가 아닌 query 정렬 열입니다. 컴퓨터에서는 masked.a3m과 대조합니다.

정답·해설 · A2의 완성 문자열과 열 번호

query	ACDEFGHIKLMN	(unchanged)
A2 before	ACDeeEFGHIKLMN	
A2 after	ACDeeEXGXIKXMN	
A2 aligned	ACDEXGXIKXMN	
A3 after	ACDE-GXIKXMN	

정렬 5·7·10열(F·H·L) → A2 원문 7·9·12번째 글자를 X로 변경

ee는 정렬 3열 뒤/4열 앞 삽입: 원문 4·5번째 글자이며 정렬 열은 없음

열 번호는 1부터 셉니다. A2 결과는 ACDeeEXGXIKXMN입니다.

소문자 ee·query 전체·기존 gap을 보존합니다. A3의 5열 -도 그대로입니다.

흔한 오류: 원문 5·7·10번째 글자를 가리거나, 먼저 대문자화해 삽입을 정렬 열로 세기.

정답·해설 · X로 가린 정보와 남긴 정보

확인 항목	정답과 이유
Query	전체 보존: 같은 표적에서 homolog 정보만 바꾸기 위해
소문자 ee	보존: 삽입 정보를 남기고 정렬 열 대응을 유지
기존 gap -	보존: X와 뜻이 다름. 열을 삭제하거나 잔기를 새로 넣지 않음
5·7·10열	homolog 잔기 정체를 X로 가려 빈도·다른 열과의 조합 정보를 약화

원본 MSA를 대조군으로 남깁니다. X는 잔기 정체를 가린 표식이며 gap과 같지 않습니다.

이것은 문자열 생성 실습입니다. AFsample2 실행·특정 접촉 제거·대안 구조 발견을 뜻하지 않습니다.

SPEACH_AF와 AFsample2는 같은 편집이 아니다

비교	SPEACH_AF 원 방법	AFsample2
편집 기호	A: alanine	X: unknown
위치 선택 근거	초기 구조의 접촉 정보	무작위 MSA 열
Query 처리	원 코드에서 함께 편집	첫 query 행 유지
공통 해석	새 구조 후보 탐색	검증 필요한 후보

SPEACH_AF: 구조 정보를 이용한 alanine 편집

AFsample2: 선택한 MSA 열을 unknown X로 가림

원래 SPEACH_AF는 query도 편집한다는 예외를 확인한다.

논문 그림 읽기: AFsample2의 입력과 출력




그림 a: 행 선택과 열 마스킹을 비교한다.
예측 뒤에는 후보 분석과 독립 검증이 필요하다.
새로운 후보가 곧 실험으로 확인된 중간 상태는 아니다.

FASTA 제목에 open을 쓰면 열릴까?

```
>sample_open  
ACDEFGHI
```

```
>sample_closed  
ACDEFGHI
```

교육용 가상 서열. 같은 문자열에 붙인 이름 두 개이며, open/closed 상태를 지정한 입력이 아니다.

Header는 식별자이며 구조 상태 명령문이 아니다.

MSA 내용과 예측 설정이 같으면 이름만으로 상태를 지정하지 못한다.

복합체에서는 header의 종 정보가 pairing에 쓰일 수 있다.

Seed·dropout·template도 별도 요인이다

요인	바뀌는 것	주의할 해석
Random seed	확률적 계산의 선택	다른 seed ≠ 다른 물리 상태
Inference dropout	계산 중 확률적 교란	온도·시간을 지정하지 않음
Template	참고 구조 정보	유도된 상태·평가 누출 점검
Recycles	예측 내부 반복	분자 운동 시간과 다름

Seed: 반복마다 사용되는 난수의 출발점

Dropout: 지원 구현에서 추론 중 일부 연산을 무작위로 끄

Template: 이미 알려진 구조 정보가 입력에 추가됨

AF2 근거를 AF3에 그대로 옮길 수는 없다

범위	확인된 내용	필요한 추가 확인
AF2 방법 연구	Subsampling·cluster·mask 사례	새 표적에서 대조 비교
로컬 AF3	Custom MSA 입력 지원	구현·설정·모델 차이
AF3 연구 확장	AFsample3 저장소 존재	표적별 검증·근거 수준

이 단원의 대표 논문들은 AF2를 시험했다.

로컬 AF3는 custom MSA를 받을 수 있다.

AF3용 구현의 존재와 검증된 성능을 구별한다.

활동지 7 · 후보 8개를 신뢰도와 함께 판독

가상 180잔기 표적 · 전체 8개 후보

ID	MSA	pLDDT	거리 Å	PAE Å
F1	원본	91	8.2	3.1
F2	원본	92	8.6	3.0
S1	얇음	88	16.4	4.4
S2	얇음	50	22.0	18.0
A1	라벨 A	90	8.5	3.3
B1	라벨 B	89	16.0	4.0
M1	X mask	87	15.8	5.2
M2	X mask	49	24.0	19.0

문제 · 근거와 함께 답하세요

- ① 서로 다른 거리의 후보 묶음을 찾으세요. 큰 거리만 보고 S2/M2를 선택해도 될까요?
- ② 평균 pLDDT가 가장 높은 모델 하나만 남기면 무엇을 놓칠 수 있나요?
- ③ 8개 중 3개가 비슷하면 평형 점유율은 3/8인가요? 더 필요한 근거는?

거리: 40–140번 C α / PAE: 20–70과 110–160 사이 양방향 평균. 실제 예측이나 앞의 A3M에서 계산한 값이 아닙니다.

정답·해설 · 거리와 신뢰도를 함께 비교

후보 묶음	가상 수치	판단 근거
F1 · F2 · A1	거리 8.2 · 8.6 · 8.5 Å	가까운 거리 후보로 묶어 검토
S1 · B1 · M1	거리 16.4 · 16.0 · 15.8 Å	첫 묶음과 다른 배치인지 검토
S2 · M2	pLDDT 50 · 49 PAE 18 · 19 Å	큰 거리 22 · 24 Å만으로 대안 구조라 부르기 어려움

F2만 고르면 S1 등의 다른 배치 후보를 놓칩니다. 각 묶음에서 대표 후보를 남깁니다.

한 개의 거리는 구조 전체를 요약하지 못합니다. 같은 구간을 정렬해 도메인 배치와 접촉을 비교합니다.

정답·해설 · 3/8은 평형 점유율이 아니다

질문	답과 이유
약16 Å 후보가 3/8개?	S1·B1·M1: 생성물에서 37.5%라는 뜻
열린 상태가 37.5% 존재?	판정 불가: 모델 생성 빈도가 물리적 평형분포라는 근거가 없음
조건별 후보를 더 비교하려면?	같은 query·모델·seed 집합·생성 수로 반복하고 입력 조건을 기록
실제 구조·점유율을 판단하려면?	구조의 물리적 타당성과 독립적인 구조·분광학 등 실험 근거 확인

MSA·seed·선별 기준을 바꾸면 생성 비율도 바뀔 수 있습니다. 높은 pLDDT도 상태의 존재 확률은 아닙니다.

최종 설명 활동

종이·구두 응답 또는 컴퓨터 실습

“Ortholog만 모으면 공변화가 곧 직접 접촉이다.”

“MSA cluster가 3개이므로 구조 상태도 3개다.”

“예측 100개 중 20개가 열렸으니 점유율은 20%다.”

각 주장에 빠진 근거를 한 문장씩 적으세요.

정답·해설 · 세 주장을 근거에 맞게 고치기

원래 주장	빠진 근거와 수정한 설명
Ortholog의 공변화 = 직접 접촉	공통 조상·간접 연관이 남습니다. 공변화는 접촉을 탐색하는 단서이며 구조 검증이 필요합니다.
MSA cluster 3개 = 구조 상태 3개	서열을 나눈 결과입니다. 서로 다른 입력에서 같은 구조가 나올 수도 있어 예측 좌표를 따로 비교합니다.
100개 중 20개 = 평형 점유율 20%	이는 생성물 비율입니다. 물리적 평형분포를 표집했다는 근거와 실험 검증이 필요합니다.

좋은 답은 “틀렸다”에서 끝나지 않고, 무엇을 관측했으며 어떤 근거가 더 필요한지 설명합니다.

오늘 배운 내용

진화 관계는 공통조상에서 일어난 사건으로 판단
공변화는 단서이며 공통 조상·기능 분화를 함께 해석
MSA 조작은 서로 다른 구조 가설을 탐색하는 도구
후보 구조는 신뢰도·재현성·실험 근거로 평가

논문과 실행 문서

Jumper et al. (2021), Highly accurate protein structure prediction with AlphaFold

<https://www.nature.com/articles/s41586-021-03819-2>

Mariani et al. (2013), IDDT: a local superposition-free structure comparison score

<https://pmc.ncbi.nlm.nih.gov/articles/PMC3799472/>

ColabFold official repository

<https://github.com/sokrypton/ColabFold>

EMBL-EBI / Google DeepMind training: pLDDT, Understanding local confidence

www.ebi.ac.uk · [원문 열기](#)

EMBL-EBI / Google DeepMind training: PAE, A measure of global confidence

www.ebi.ac.uk · [원문 열기](#)

전체 출처와 논문 그림 라이선스: content/sources.json 및 발표자 노트