

MSA와 단백질 구조 예측

진화 관계와 대안 구조 탐색

Ortholog·paralog와 공진화(coevolution)를 구조 예측의 단서로 읽기

개념 설명 직후 짧은 실습 · 휴식 포함 3시간

Homology: 얼마나 닮았나보다 어디에서 왔나

용어	무엇을 말하나
Homology	공통 조상에서 유래한 관계
Identity	정렬에서 같은 잔기의 비율
Similarity	정의한 점수 체계에서 유사한 잔기 관계

상동성(homology)은 공통 조상에서 유래했다는 관계

“70% homology” 대신 “정의한 정렬에서 70% identity”라고 표현

Ortholog와 paralog: 갈라진 사건을 묻는다

관계	기준 사건	기억할 점
Ortholog	종 분화(Speciation, S)	기능 동일성을 보장하지 않음
Paralog	유전자 중복(Duplication, D)	같은 종 또는 다른 종에 존재


두 유전자의 가장 최근 공통 조상에서 일어난 사건을 확인

종 이름·서열 유사도·기능의 같고 다름만으로 정하지 않음


Species tree와 gene tree는 다른 질문

교육용 가상 예시

Species tree



Gene tree



S = 종 분화, D = 유전자 중복


A와 B는 종 이름; A_g1 등은 유전자 이름

Species tree: 종들의 분기 관계

Gene tree: 특정 유전자 가족의 계보와 중복·소실

예제 1: 종 분화보다 먼저 중복되었다면

교육용 가상 계통수: 중복 → 종 분화



D에서 1번·2번 유전자 계열이 먼저 나뉨


두 S는 같은 A-B 종 분화를 각 유전자 계열에서 표시

A_1-B_1은 ortholog; A_1-A_2와 A_1-B_2는 paralog

같은 종 안의 관계와 다른 종 사이의 관계를 모두 확인

예제 2: 종 분화 뒤에 중복되었다면

교육용 가상 계통수: 종 분화 → 중복



A 계통에만 중복이 생긴 경우

A_1-B_1과 A_2-B_1은 각각 orthology 관계

A_1과 A_2는 서로 paralog

A_1과 A_2는 각각 B_1의 ortholog: B_1에 대한 co-orthologs

Paralog는 종 안에도, 종 사이에도 있다

관찰 또는 용어	해석 기준
Within-species paralog	같은 종의 두 유전자; 조상 중복 시점은 별도 확인
Between-species paralog	다른 종의 두 유전자; 공통 조상 노드는 D
Inparalog / outparalog	기준 종 분화 뒤 / 앞의 중복에서 유래

“같은 종이면 paralog, 다른 종이면 ortholog”는 불완전한 규칙

In-/out-paralog는 비교하는 종 분화 시점에 대한 상대적 용어

유전자 소실: 남은 하나끼리 비교하면 생기는 착시

교육용 가상 계통수: 중복 뒤 서로 다른 사본 소실



현재 관찰되는 유전자는 A_1과 B_2


현재 사본 수와 과거 분기 사건을 구분

각 종에 한 개씩 남았어도 일대일 ortholog라는 보장은 없음

다른 종의 서열·유전자 계통수·주변 유전자 정보가 판별에 도움

바로 실습 · Ortholog와 paralog 판정

교육용 가상 계통수



가지 길이는 의미 없음

현재 이름이 아니라 가장 최근 공통 조상 사건으로 판정

① A_x-A_y ② A_x-B_z ③ A_y-B_z 관계를 판정

각 쌍의 공통 조상에 동그라미 → S/D → 관계 이름

활동지 1쪽: 분기 사건을 표시하고 짝과 비교

Ortholog여도 기능이 완전히 같지는 않다

알 수 있는 것	추가 확인할 것
Orthology / paralogy	기원과 분기 사건
높은 서열 동일성	정렬 길이·도메인 구성·진화 관계
비슷한 예측 구조	기질·활성·발현·실험 조건

진화 관계는 기능 추론의 근거이며 기능 실험의 대체물이 아님

최고 유사도 hit 하나만으로 orthology 또는 기능을 확정하지 않음

유전자 가족에서 MSA로: 대응 위치를 제안한다

Multiple sequence alignment(MSA): 여러 상동 서열의 대응 위치를 정렬
정렬은 비교를 위한 가설이며 모든 열이 정확하다는 보장은 없음
너무 먼 서열·부분 서열·다른 도메인 구성은 별도 점검

MSA 읽기: 행·열·query·gap

교육용 가상 서열: 실제 단백질 아님

정렬 열	123456789
query	AC-DEFGHI
seq_A	ACQDEYGHI
seq_B	AC-NEFG-I
seq_C	AS-DEF-HI

4행 × 9열; query의 실제 길이는 8잔기

3열의 Q는 query에 대응 잔기가 없는 삽입 위치

행(row)은 서열, 열(column)은 대응 위치, “-”는 gap

Query는 이번 분석의 기준 서열; 항상 조상 서열이라는 뜻은 아님

Gap 하나가 잔기 번호를 바꾼다

교육용 가상 서열

정렬 열	1	2	3	4	5	6	7	8	9
query	A	C	-	D	E	F	G	H	I
query 잔기	1	2	-	3	4	5	6	7	8

정렬 4열 = query의 D3

원래 query 서열: ACDEFGHI

정렬 열 번호와 query 잔기 번호를 구분해서 기록

Gap만으로 삽입·결실의 진화 방향을 확정할 수 없음

FASTA: 이름 줄과 서열 줄부터 읽기

```
>query_synthetic    educational example  
ACDEFGHI  
>seq_A_synthetic    educational example  
ACQDEYGHI
```

두 서열의 실제 길이는 8과 9

이 텍스트는 정렬 전의 교육용 가상 FASTA

“>”로 시작하는 줄은 이름·설명, 다음 줄은 서열

여러 FASTA 서열이 있다고 자동으로 MSA가 되는 것은 아님

A3M: 대문자와 소문자는 서로 다른 역할

교육용 가상 A3M

```
>query
```

```
ACDEFGHI
```

```
>seq_A
```

```
ACqDEYGHI
```

```
>seq_B
```

```
ACNEFG-I
```

seq_A: q는 삽입, Y는 대응 열의 치환

겉보기 문자 수가 달라도 같은 match 열을 표현 가능

대문자 = match 상태의 잔기; 소문자 = 삽입 잔기; “-” = 결실 표시

Match는 query와 같은 아미노산이라는 뜻이 아님

바로 실습 · A3M의 열과 삽입 읽기

종이·구두 응답 또는 컴퓨터 실습

활동지 2쪽 또는 `fictional_learning.a3m`을 펼치세요.

Query를 포함한 행 수와 정렬 열 수를 세어 보세요.

A2의 ee는 어느 정렬 열 직전에 있나요?

A3의 gap과 B1의 X 위치·의미를 적으세요.

Coverage와 identity: 분모를 함께 적는다

교육용 정의	계산
Query coverage	짜지어진 query 잔기 수 / query 길이
Identity	같은 잔기 수 / 양쪽에 잔기가 있는 비교 위치 수
보고 예	identity 80%, coverage 25%; 각 분모도 기록

Coverage: query의 어느 정도를 비교했는가?

Identity: 비교한 위치 중 어느 정도가 같은 잔기인가?

바로 실습 · Coverage와 identity 계산

교육용 가상 서열

query ACDEFGHI

A ACDE----

B ACNEYGHI

A의 끝부분 gap은 query 위치를 덮지 않음

Coverage와 identity의 분모를 각각 적기

Query 길이 8; A와 B 각각 coverage와 identity를 계산

분모는 앞 장의 교육용 정의를 사용

전체 query를 설명할 때 어떤 차이를 함께 보고해야 하는가?

Conservation: 한 열에서 무엇이 유지되는가?

교육용 가상 서열

seq_1 ACDK

seq_2 ASDK

seq_3 ACEK

seq_4 ASER

열 1234

보존도는 한 열의 잔기 분포에 대한 질문

“모두 같다”와 “서로 독립적인 근거가 많다”를 구분

한 위치의 잔기 분포를 읽는 것이 보존도(conservation)

보존된 위치는 구조·기능 제약의 후보이며 원인은 추가 확인

보존·공변이·공진화는 서로 다른 질문

개념	무엇을 묻는가?	예
Conservation 보존	한 위치에서 어떤 잔기가 유지되는가?	위치 i가 대부분 D
Covariation 공변이	두 위치의 조합이 독립적 분포와 다른가?	i가 D이면 j가 K인 경향
Coevolution 공진화	위치들의 진화가 어떻게 서로 의존하는가?	구조·기능 제약을 함께 만족

이 강의에서는 관찰한 통계 패턴과 그 패턴의 진화적 설명을 구분

Ortholog/paralog는 행 사이의 관계; 잔기 공변이는 열 사이의 관계

한 위치의 선택은 다른 위치에 달릴 수 있다

두 위치의 조합	전하	가상 모형의 해석
D-K	음 / 양	반대 전하 조합
K-D	양 / 음	반대 전하 조합
D-D 또는 K-K	음 / 음 또는 양 / 양	이 가상 모형에서는 덜 유리하다고 가정

가정: 가까운 두 위치에서 반대 전하의 조합이 유리한 가상 상황

D-K와 K-D는 조합 예시; 실제 치환 순서·동시 발생·접촉의 증거가 아님

두 열의 빈도와 조합 빈도를 따로 센다

8행의 가상 자료	j = D	j = K	행 합계
i = D	0	4	4
i = K	4	0	4
열 합계	4	4	8

관찰: $P(D_i, K_j) = 4/8 = 1/2$

독립이라면: $P(D_i) \times P(K_j) = 1/2 \times 1/2 = 1/4$

이 가상 자료에는 통계적 의존성이 있음; 그 원인은 아직 모름

즉시 실습: 같은 열 빈도, 다른 조합

가상 조합	자료 P: 8행	대조 자료 Q: 8행
D-D	0	2
D-K	4	2
K-D	4	2
K-K	0	2

각 자료에서 $P(D_i)$, $P(K_j)$, $P(D_i, K_j)$ 를 계산

$P(D_i, K_j)$ 를 $P(D_i) \times P(K_j)$ 와 비교

단일 열의 보존도만으로 두 자료를 구별할 수 있는가?

휴식 · 10분

10분 뒤 다시 시작합니다.

다음: 공변화 패턴을 유전자 계통과 함께 해석하기

Ortholog를 모아도 공통 조상은 남아 있다

질문	Ortholog를 모으면?
다른 중복 계열의 혼합인가?	대상 계열을 맞추는 데 도움이 됨
각 서열은 독립 관측인가?	아님: 가까운 종은 조상의 패턴을 공유
모든 위치가 같은 제약을 받나?	보장 없음: 계통별 기능·환경 차이도 가능

Ortholog 관계는 비교할 유전자 계열을 정리하는 데 도움

후손 100개의 같은 조합 ≠ 독립적인 보상 치환 100회

계통수의 여러 가지에서 반복되었는지는 따로 평가해야 함

Paralog 혼합은 계열 차이를 함께 섞는다

같은 MSA를 보는 방법	확인할 것
모든 상동 서열을 합침	관찰한 조합이 하위 계열 이름을 구별하는가?
중복 계열별로 나눔	각 계열 안에도 두 위치의 변화가 있는가?
계열을 제외함	혼합 효과와 함께 유용한 다양성도 잃는가?

두 하위 계열이 각각 다른 잔기를 선호하면 혼합 후 공변이가 생길 수 있음

Ortholog만 남기는 규칙 대신 분석 목적·정렬·계열 구성을 함께 점검

즉시 실습: 계열을 나누면 무엇이 보이나?

가상 서열: 각 이름이 한 행	i	j
A_H, A_M, A_R, A_F	모두 D	모두 K
B_H, B_M, B_R, B_F	모두 K	모두 D

가정: A/B로 중복 → H/M/R/F 종 분화; 추가 중복·소실 없음

A_H-A_M, A_H-B_H, A_H-B_M의 진화 관계는?

전체와 계열 내부를 비교: 변화·공변이를 각각 판단

8행을 독립적인 보상 치환 8회라고 셀 수 있는가?

복합체에서는 어떤 서열끼리 짝지었는가?

분석	한 행의 의미	핵심 확인
단백질 내부	한 상동 단백질의 서열	같은 서열의 위치 i와 j
단백질 사이	단백질 P 서열 Q 서열	P의 위치 i와 Q의 위치 j
같은 종에 여러 paralog	P1/P2와 Q1/Q2 존재	P1의 상대가 Q1인가 Q2인가?

Paired MSA는 서로 다른 단백질의 서열을 같은 행에 대응시킴

같은 종에 있다는 사실만으로 실제 결합 파트너를 확정할 수 없음

함께 변한다고 모두 직접 연결된 것은 아니다

접근	무엇을 하는가?
공변이·MI	두 열의 관찰 분포가 독립적인지 비교
DCA	여러 열을 함께 모형화해 직접·간접 통계 효과를 구분
AlphaFold	학습한 모형으로 서열·MSA 등 정보를 통합해 구조 예측

i - k 와 k - j 관계만 있어도 i - j 에 간접 상관이 생길 수 있음

추정한 coupling도 실제 접촉·작동 기전의 자동 증명이 아님

Depth·clustering·masking은 무엇을 바꾸나?

조작	공변이 관점에서 달라지는 정보
Depth 줄이기	조합을 추정할 행 수와 표집된 다양성
MSA clustering	선택된 서열 계열과 그 안의 조합 빈도
Masking	특정 위치의 잔기 및 그 위치가 참여하는 조합 정보

같은 query에도 제공되는 잔기 분포·조합·계열 구성이 달라짐

다른 구조가 나와도 생물학적 상태·존재 비율은 별도 검증

Raw depth와 Neff: 행 수와 다양성은 다르다

교육용 재가중 예	Raw depth	가중치 합
완전히 동일한 서열 100개	100	$100 \times 1/100 = 1$
서로 기준 이상 유사한 쌍이 없는 100개	100	$100 \times 1 = 100$
실제 MSA	행 수를 기록	정의·유사도 기준·coverage도 기록

Raw depth는 서열 행 수; 같은 서열이 많아도 그대로 증가

Neff는 중복·유사도를 반영하는 지표이며 계산법을 반드시 명시

서열에서 예측 구조까지

Query: 구조를 알고 싶은 단백질의 아미노산 서열

MSA: 진화적으로 관련된 서열을 정렬한 입력

모델: 서열·MSA·선택한 추가 정보를 함께 처리

출력: 원자 좌표와 모델이 추정된 신뢰도

AlphaFold2와 AlphaFold3

항목	AlphaFold2 계열	AlphaFold3
주요 입력	단백질 서열·MSA·template	단백질·핵산·리간드 등
좌표 생성	구조 모듈과 recycling	Diffusion 기반 생성
이 강의에서 역할	MSA 조작의 주요 실습 도구	기본 예측과 확장 적용 비교
해석 원칙	여러 예측을 만들고 검증	별도 검증 후 기법 적용

이 강의의 MSA 조작 사례는 주로 AF2에서 검증되었습니다.

웹 서버와 로컬 실행

웹 서버: 서열과 분자를 입력해 빠르게 시작

로컬 AF3: JSON으로 custom MSA-template 지정

MSA 조작 실습: custom A3M을 받는 ColabFold 활용

실제 예측에는 모델 설치·계산 자원이 필요

Custom MSA의 기본 조건

첫 번째 서열은 예측할 query와 일치

정렬 열은 query의 위치와 대응

A3M의 소문자는 insertion, 대문자·gap은 정렬 열
비교할 때 query·template·모델 버전을 함께 기록

ColabFold 1 · 접속과 실습 준비

아래 URL을 브라우저 주소창에 붙여 넣고 Google 계정으로 로그인
필요하면 File → Save a copy in Drive로 개인 사본 저장
사용할 파일: examples/calmodulin_P0DP23.fasta
이 수업에서는 단백질 한 사슬, 149개 아미노산을 입력

<https://colab.research.google.com/github/sokrypton/ColabFold/blob/main/AlphaFold2.ipynb>

ColabFold 2 · GPU와 노트북 실행 방식

Runtime → Change runtime type → GPU 선택 → Save

한국어 메뉴: 런타임 → 런타임 유형 변경

코드 셀은 왼쪽 ▶로 실행하며, 위에서 아래로 이어집니다.

GPU를 할당받지 못하면 교사 결과·오프라인 활동으로 진행

ColabFold 3 · 서열과 기본 조건 입력

화면 항목	이번 실습의 입력	의미
query_sequence	CALM1 전체 서열 149 aa	예측할 단백질
jobname	calm_baseline	결과를 구분할 이름
num_relax / template_mode	0 / none	처음에는 template 없이
msa_mode	mmseqs2_uniref_env	검색으로 기본 MSA 생성

FASTA의 >로 시작하는 제목 줄을 빼고 서열만 붙여넣기

첫 셀 출력에서 length 149와 실제 서열을 확인

ColabFold 4 · Run all과 계산 진행 확인

Advanced settings: model_type=alphafold2_ptm, num_recycles=3

Sample settings: max_msa=auto, num_seeds=1, use_dropout 해제

Runtime → Run all / 런타임 → 모두 실행

설치 → MSA 검색 → Run Prediction → 결과 표시 순서 확인

ColabFold 5 · 결과와 MSA 다운로드

Display 3D structure에서 rank_num과 잔기별 색 확인

Plots에서 MSA coverage·pLDDT·PAE 확인

Package and download results의 실행 버튼으로 결과 ZIP 저장

ZIP의 .a3m·구조 .pdb·설정/로그를 함께 보관

IDDT · 기준 구조의 주변 거리가 얼마나 보존되었나?

IDDT = local Distance Difference Test · 기준 구조와 비교하는 정확도 점수
원 지표는 원자 단위 평가. 여기서는 AF2의 잔기별 IDDT- $C\alpha$ 를 사용

① 기준 구조에서 중심 $C\alpha$ 의 15 Å 미만 이웃을 선택

② 거리 오차 $|\text{예측 거리} - \text{기준 거리}|$ 를 0.5·1·2·4 Å로 검사

전체 구조를 겹칠 필요는 없지만, 대응 잔기와 기준 좌표는 필요

직접 계산 · 네 이웃의 거리 오차를 네 번 채점

이웃	기준 거리 (Å)	예측 거리 (Å)	절대 오차 (Å)	통과 수 / 4
a	4.0	4.2	0.2	4 / 4
b	7.0	7.8	0.8	3 / 4
c	10.0	11.5	1.5	2 / 4
d	14.0	17.0	3.0	1 / 4

중심 잔기 i의 가상 이웃 4개만 사용. 오차 < 0.5, < 1, < 2, < 4 Å를 각각 검사

오차 0.8 Å는 1·2·4 Å 검사를 통과합니다. 네 검사는 겹칩니다.

$$IDDT_i = (4 + 3 + 2 + 1) / (4 \times 4) = 0.625 \rightarrow 100\text{점 척도로 } 62.5$$

바로 실습 · 예측 거리가 더 멀어지면?

종이·구두 응답 또는 컴퓨터 실습

활동지 5쪽: 마지막 이웃 d의 예측 거리만 $17 \rightarrow 19 \text{ \AA}$ 로 변경
기준 거리는 여전히 $14 \text{ \AA}$. 나머지 세 이웃은 같습니다.

- ① d는 네 검사 중 몇 개를 통과하나요? 새 IDDT_i는?
- ② 예측 거리가 $15 \text{ \AA}$ 를 넘으면 이 이웃을 빼도 될까요?

pLDDT가 나온 과정 · 채점한 IDDT를 학습 정답으로

AF2 학습 단계	사용 정보	만드는 것
① 구조 예측	서열·MSA 등	예측 좌표 + 잔기별 내부 표현
② 정답 점수 계산	예측 좌표 + 학습용 기준 좌표	실제 계산한 잔기별 IDDT- $C\alpha$
③ 신뢰도 학습	내부 표현 → 신뢰도 head	IDDT의 50개 구간에 대한 분포

예: 계산한 IDDT 0.625 → [0.62, 0.64) 구간이 학습 정답

예측 분포가 정답 구간을 맞히도록 학습합니다(cross-entropy).

기준 좌표는 채점·지도에 사용하며, 신뢰도 head에 정답으로 입력하지 않습니다.

새 서열에서는 정답 없이 pLDDT를 출력한다

구간 중심 c_k	예측 확률 p_{ik}	$p_{ik} \times c_k$
0.49	0.10	0.049
0.69	0.20	0.138
0.89	0.70	0.623

AF2: 잔기별 50 logits → softmax 확률 → $pLDDT_i = 100 \times \sum_k p_{ik}c_k$

가상 예: 50개 중 세 구간에만 확률을 둔 단순화 → $100 \times 0.810 = 81점$

81은 예측한 IDDT 점수이며 ‘정답 확률 81%’도 ‘오차 81 Å’도 아닙니다.


pLDDT의 네 가지 색 · 숫자와 함께 읽기

점수 범위	보통의 표시색	해석의 출발점
$90 \leq \text{점수} \leq 100$	진한 파랑	매우 높은 국소 신뢰도
$70 \leq \text{점수} < 90$	하늘색	대체로 믿을 만한 골격
$50 \leq \text{점수} < 70$	노랑	낮은 신뢰도, 세부 해석 주의
$0 \leq \text{점수} < 50$	주황	매우 낮음, 좌표 해석을 보류

색은 신뢰도를 쉽게 보기 위한 표시입니다. 화면의 범례를 확인하세요.

구간 경계는 해석 지침이며, 특정 값에서 정확도가 갑자기 바뀌지 않습니다.

평균 82.8점이 가리는 낮은 신뢰도 구간



가상 개념도(실제 예측 아님): A 1-5 / 연결부 6-7 / B 8-12

전체 평균 82.8 / A·B 각각 91.2 / 연결부 41.0

평균과 함께 잔기별 그래프·3D 색·관심 부위를 확인

바로 실습 · pLDDT 그래프에서 말할 수 있는 것

종이·구두 응답 또는 컴퓨터 실습

활동지 6쪽: 먼저 pLDDT 문제만 풉니다.

- ① 가장 조심해서 해석할 위치 두 곳을 찾으세요.
- ② 평균 82.8이면 12개 위치가 모두 믿을 만한가요?
- ③ A와 B의 상대 방향·연결부의 disorder를 확인할 수 있나요?

PAE · 기준을 고정하면 다른 위치는 얼마나 불확실할까?

PAE = Predicted Aligned Error, 예측 정렬 오차

PAE(i, j): j 의 국소 좌표계를 맞췄다고 할 때 i 의 예상 위치 오차

단위 Å, 낮을수록 상대 위치를 더 확신 / 이 예제: 행 i ·열 j

두 잔기 사이 거리나 두 실물 구조에서 측정한 RMSD와 다릅니다.

PAE 표 읽기 · 도메인 내부와 도메인 사이

i ↓ / j →	A3	A4	B9	B10
A3	0	1	18	20
A4	1	0	19	21
B9	24	23	0	2
B10	22	24	2	0

가상 예제의 3·4·9·10번만 선택한 4×4 표 / 단위 Å

행 = 평가할 i / 열 = 정렬 기준 j / 도메인 사이 두 방향 모두 확인

교육용 색: 진한 청록 0–2 Å / 옅은색 18–24 Å (낮을수록 더 신뢰)

두 점수 함께 읽기 · 부분의 모양과 상대 배치

높은 pLDDT + 낮은 내부 PAE → 각 도메인 내부 구조를 더 신뢰

높은 도메인 사이 PAE → 두 도메인의 상대 배치는 불확실

유연성·disorder는 가능한 설명이며, 점수만으로 확정하지 않음

낮은 PAE도 실제 결합·상태 점유율·전이 속도를 증명하지 않음

바로 실습 · 같은 pLDDT, 다른 PAE

종이·구두 응답 또는 컴퓨터 실습

활동지 6쪽: P는 앞의 표, Q는 같은 pLDDT를 갖는 다른 가상 예측

Q의 선택된 4×4 PAE에서 대각선 밖 값은 모두 1–3 Å

① $PAE(A3, B9)=18$ 과 $PAE(B9, A3)=24$ 를 각각 말로 풀어 보세요.

② P·Q 중 상대 배치를 더 확신하는 것은? 실제 상태 비율도 알 수 있나요?

휴식 · 10분

10분 뒤 다시 시작합니다.

다음: custom MSA와 depth·clustering·masking 실습

ColabFold 6 · Custom MSA 업로드

새 jobname 입력 · query_sequence는 동일하게 유지

MSA options에서 msa_mode를 custom으로 선택

Runtime → Run all → 업로드 창에서 .a3m 한 개 선택

첫 query가 CALM1 149 aa인지 확인하고 결과 ZIP 저장

AF3에서 custom MSA 지정

```
"protein": {  
  "id": "A",  
  "sequence": "<full query sequence>",  
  "unpairedMsaPath": "target.a3m",  
  "pairedMsa": "",  
  "templates": []  
}
```

unpairedMsaPath: 직접 준비한 A3M

pairedMsa: 단량체 실습에서는 빈 값

templates: template 비교 조건 고정

아래는 protein 항목의 형식 예시입니다.

실제 FASTA와 A3M을 사용한 완전한 JSON은 [examples/](#)에서 생성합니다.

한 번에 한 조건씩 비교

Baseline: 원본 MSA와 정해진 seed 목록

Depth: 행 수만 줄여 여러 번 표본 추출

Cluster: 비슷한 서열 집단별 입력

Mask: 정해진 열의 정보만 가리는 조건

바로 실습 · 공정한 비교 설계

설계	조건 1	조건 2
A	Query Q / template 없음 / 5회	Query Q 일부 삭제 / template 있음 / 50회
B	Query Q / 전체 MSA / 10회	Query Q / 선택 MSA / 10회
B의 공통 조건	모델·template·seed 집합	같이 유지

질문: MSA 행 선택의 효과를 알고 싶다.

A/B 중 더 공정한 비교를 고르고 이유를 적는다.

고정할 것 2개, 기록할 것 2개를 짝과 공유한다.

기준 예측부터 기록한다

먼저 고정	변경 후보	함께 기록
Query·모델 버전	MSA 행 또는 열	입력 파일·행 수
Template 조건	Seed·dropout	반복 수·실행 설정
구조 비교 구간	한 조건씩 비교	pLDDT·PAE·구조 차이

같은 단백질의 입력 근거를 바꾸어 비교한다.

Query 서열·길이·번호를 먼저 고정한다.

한 번에 바꾸는 조건과 반복 횟수를 기록한다.

행을 줄인다: MSA subsampling

원래 MSA

query	ACDEFGHI
hom1	AC-EYGHI
hom2	ACDEFG-I
hom3	ACNEFGHI

선택한 MSA

query	ACDEFGHI
hom1	AC-EYGHI
hom3	ACNEFGHI

교육용 가상 정렬. Query 행은 유지하고, homolog 행의 일부를 택한다. 열과 query 길이는 유지한다.

행(row) = 정렬에 포함된 서열 하나

Query는 남기고 homolog 행 일부를 선택한다.

행 수 감소는 정보 감소와 다양성 변화를 함께 만든다.

바로 실습 · Depth를 줄인 MSA

종이·구두 응답 또는 컴퓨터 실습


활동지 4쪽 1번: query와 A2·A3·B1만 남겨 보세요.

컴퓨터: practice/에서 python3 msa_lab.py 실행

출력 폴더의 subsample.a3m: 첫 행·행 수·열 수 확인

원본과 비교해 줄어든 진화 정보는 무엇인가요?

논문 그림 읽기: 얇은 MSA의 효과와 한계



점 하나는 예측 구조 하나: 실험 구조와 비교한다.
MSA 깊이에 따라 구조 분포가 달라진 사례가 있다.
다양성 증가에는 잘못 접힌 구조도 섞일 수 있다.

[del Alamo et al., eLife \(2022\), Fig. 1A \(발체\)](#)


[CC BY 4.0](#)

ColabFold 7 · 화면에서 MSA depth 비교

화면 항목	비교 A	비교 B
jobname	calm_depth32	calm_depth64
msa_mode	custom · 동일 A3M	custom · 동일 A3M
max_msa	32:64	64:128
고정 항목	같은 모델·seed 수·template	같은 설정 유지

같은 A3M을 custom으로 재사용하고 max_msa만 변경
두 숫자는 주 MSA·extra MSA 한도이며 총 행 수가 아닙니다.

AF-Cluster: 서열을 먼저 나누어 예측



MSA의 homolog를 서열 유사성으로 나눈다.
각 sub-MSA를 별도로 AF2에 입력한다.
KaiB의 알려진 다른 접힘을 탐색한 사례가 있다.

[Wayment-Steele et al., Nature \(2024\), Fig. 1d \(발췌\)](#)

[CC BY 4.0](#)

각 cluster에도 같은 query가 들어간다

Cluster A 입력

```
>query  
ACDEFGHI  
>hom1  
AC-EYGHI
```

Cluster B 입력

```
>query  
ACDEFGHI  
>hom3  
ACNEFGHI
```

교육용 가상 정렬. 두 입력의 query는 동일하고, 그 아래 homolog 조합만 다르다.

예측 대상 = query, 배경 정보 = homolog 집합

Cluster마다 query를 맨 앞에 다시 넣는다.

Cluster 대표 서열로 query를 바꾸면 대상도 바뀐다.

바로 실습 · 서열 그룹별 입력 비교

종이·구두 응답 또는 컴퓨터 실습

활동지 4쪽 2번: group_A/B.a3m을 비교하세요.

두 파일의 첫 query와 homolog 구성을 확인

각 그룹에서 5열·11열의 잔기 분포를 읽어 보세요.

이 그룹을 ortholog 집합이나 구조 상태라 부를 수 있나요?

서열 cluster는 열역학적 상태가 아니다

분류 질문	사용 정보	바로 알 수 없는 것
어떤 서열이 닮았나?	서열 유사성	구조 상태의 수
어떤 진화 관계인가?	유전자·종 계통	상태별 점유율
어떤 구조가 다른가?	좌표·접촉·실험	전환 속도

서열 유사성은 진화적 관련성과 기능 차이를 섞어 담는다.

Ortholog / paralog 구분과 구조 상태 구분은 다른 문제다.

Cluster 수·크기에서 상태 수·점유율을 바로 읽지 않는다.

2025년 논쟁: 비교 조건을 읽는다

자료	핵심 질문	읽을 때 확인
Nature 비판 (2025)	무작위 표본보다 나은가?	표적·표본 수·AF2 설정
JMB 응답 (2025)	진화 신호를 직접 시험했나?	대조군·추가 분석
우리 비교 설계	무엇 하나가 달랐나?	동일 조건·독립 평가

Matters Arising은 무작위 표본 비교와 해석을 비판했다.

저자 응답은 비교 조건과 진화 신호의 역할을 재검토했다.

강의 결론: 같은 조건의 대조군과 독립 검증이 필요하다.

두 가지 clustering을 구별한다

단계	묶는 대상	목적
AF2 이전	MSA 서열 행	다른 입력 근거 만들기
AF2 이후	예측 구조 후보	중복 정리·대표 선택
실험 검증 이후	관찰된 상태	물리적 해석 뒷받침

입력 clustering: 예측 전에 서열을 묶는다.

출력 clustering: 예측 후 구조를 묶는다.

많은 입력 cluster가 같은 구조를 만들 수도 있다.

열을 가린다: unknown X와 gap의 차이

원래		한 열을 X로 마스킹	
query	ACDEFGHI	query	ACDEFGHI
hom1	AC-EYGHI	hom1	AC-XYGHI
hom2	ACDEFG-I	hom2	ACDXFG-I
	↑		↑

교육용 가상 정렬. X = unknown residue, - = gap. Query 첫 행과 전체 정렬 열 수는 바꾸지 않는다.

열(column) = query의 정렬 위치에 대응

X는 종류를 모르는 잔기, -는 정렬의 gap이다.

오늘 실습에서는 query를 보존한 채 정보만 가린다.

바로 실습 · 정렬 열을 X로 가리기

종이·구두 응답 또는 컴퓨터 실습

활동지 4쪽 3번: A2의 5·7·10열을 X로 가리세요.

소문자 ee를 정렬 열로 세지 않고 원문을 다시 쓰기

masked.a3m에서 query-insertion·기존 gap 확인

어느 열의 빈도와 열 사이 조합 정보가 사라졌나요?

SPEACH_AF와 AFsample2는 같은 편집이 아니다

비교	SPEACH_AF 원 방법	AFsample2
편집 기호	A: alanine	X: unknown
위치 선택 근거	초기 구조의 접촉 정보	무작위 MSA 열
Query 처리	원 코드에서 함께 편집	첫 query 행 유지
공통 해석	새 구조 후보 탐색	검증 필요한 후보

SPEACH_AF: 구조 정보를 이용한 alanine 편집

AFsample2: 선택한 MSA 열을 unknown X로 가림

원래 SPEACH_AF는 query도 편집한다는 예외를 확인한다.

논문 그림 읽기: AFsample2의 입력과 출력




그림 a: 행 선택과 열 마스킹을 비교한다.
예측 뒤에는 후보 분석과 독립 검증이 필요하다.
새로운 후보가 곧 실험으로 확인된 중간 상태는 아니다.

[Kalakoti & Wallner, Communications Biology \(2025\), Fig. 1a \(발취\)](#)

[CC BY 4.0](#)

FASTA 제목에 open을 쓰면 열릴까?

```
>sample_open  
ACDEFGHI
```

```
>sample_closed  
ACDEFGHI
```

교육용 가상 서열. 같은 문자열에 붙인 이름 두 개이며, open/closed 상태를 지정한 입력이 아니다.

Header는 식별자이며 구조 상태 명령문이 아니다.

MSA 내용과 예측 설정이 같으면 이름만으로 상태를 지정하지 못한다.

복합체에서는 header의 종 정보가 pairing에 쓰일 수 있다.

Seed·dropout·template도 별도 요인이다

요인	바뀌는 것	주의할 해석
Random seed	확률적 계산의 선택	다른 seed ≠ 다른 물리 상태
Inference dropout	계산 중 확률적 교란	온도·시간을 지정하지 않음
Template	참고 구조 정보	유도된 상태·평가 누출 점검
Recycles	예측 내부 반복	분자 운동 시간과 다름

Seed: 반복마다 사용되는 난수의 출발점

Dropout: 지원 구현에서 추론 중 일부 연산을 무작위로 끄

Template: 이미 알려진 구조 정보가 입력에 추가됨

AF2 근거를 AF3에 그대로 옮길 수는 없다

범위	확인된 내용	필요한 추가 확인
AF2 방법 연구	Subsampling·cluster·mask 사례	새 표적에서 대조 비교
로컬 AF3	Custom MSA 입력 지원	구현·설정·모델 차이
AF3 연구 확장	AFsample3 저장소 존재	표적별 검증·근거 수준

이 단원의 대표 논문들은 AF2를 시험했다.

로컬 AF3는 custom MSA를 받을 수 있다.

AF3용 구현의 존재와 검증된 성능을 구별한다.

바로 실습 · 대안 구조 후보 선택

후보	평균 pLDDT	구간 간 PAE	C α 거리
F1	91	3.1 Å	8.2 Å
S1	88	4.4 Å	16.4 Å
S2	50	18.0 Å	22.0 Å
F2	92	3.0 Å	8.6 Å

가상 180잔기 표적의 사고 실험이며 실제 예측이 아닙니다.

거리: 40–140번 C α / PAE: 두 지정 구간 사이 평균

최종 설명 활동

종이·구두 응답 또는 컴퓨터 실습

“Ortholog만 모으면 공변화가 곧 직접 접촉이다.”

“MSA cluster가 3개이므로 구조 상태도 3개다.”

“예측 100개 중 20개가 열렸으니 점유율은 20%다.”

각 주장에 빠진 근거를 한 문장씩 적으세요.

오늘 배운 내용

진화 관계는 공통조상에서 일어난 사건으로 판단
공변화는 단서이며 공통 조상·기능 분화를 함께 해석
MSA 조작은 서로 다른 구조 가설을 탐색하는 도구
후보 구조는 신뢰도·재현성·실험 근거로 평가

논문과 실행 문서

Jumper et al. (2021), Highly accurate protein structure prediction with AlphaFold

<https://www.nature.com/articles/s41586-021-03819-2>

Mariani et al. (2013), IDDT: a local superposition-free structure comparison score

<https://pmc.ncbi.nlm.nih.gov/articles/PMC3799472/>

ColabFold official repository

<https://github.com/sokrypton/ColabFold>

EMBL-EBI / Google DeepMind training: pLDDT, Understanding local confidence

www.ebi.ac.uk · [원문 열기](#)

EMBL-EBI / Google DeepMind training: PAE, A measure of global confidence

www.ebi.ac.uk · [원문 열기](#)

전체 출처와 논문 그림 라이선스: content/sources.json 및 발표자 노트