

MSA와 protein structure 예측

evolutionary relationship와 대안 structure 탐색

먼저 MSA가 AlphaFold에 주는 정보와 중요한 이유를 이해하기

evolutionary relationship·coevolution → MSA 조작 → structure와 confidence 읽기

개념 설명 직후 짧은 실습 · 휴식 포함 3시간

AlphaFold에서 MSA는 어디에 쓰일까?

순서	정보의 흐름
① Query 입력	structure를 알고 싶은 protein의 amino acid sequence
② 검색·alignment	homologous sequence 검색 → multiple sequence alignment(MSA)
③ model의 inference	Query·MSA·선택적 template → residue 사이 관계 inference
④ structure 출력	atom coordinates + prediction confidence(pLDDT·PAE)

MSA = Multiple Sequence Alignment · 관련 sequence의 대응 위치를 나란히 alignment

MSA는 이미 training된 model이 예측할 때 읽는 입력입니다.

AF2/ColabFold의 흐름입니다. AF3도 MSA를 쓰지만 내부 처리 방식은 다릅니다.

sequence 한 줄에서는 보이지 않던 단서가 생긴다

position	1	2	3	4	5	6	7	8
query	A	C	D	G	F	K	L	M
homolog1	A	C	E	G	Y	R	I	M
homolog2	V	C	K	A	F	D	L	M
homolog3	V	C	R	A	Y	E	I	M

교육용 가상 MSA · position: alignment 위치 / 행: 관련 sequence 하나 / 열: 대응 위치

2열 C·8열 M: 여러 sequence에서 유지되는 위치 → conservation

3·6열: D/K, E/R, K/D, R/E로 조합이 함께 달라짐 → covariation

Coevolution 패턴은 3차원에서 가까운 residue 쌍을 추정하는 단서입니다. 다음 그림에서 확인합니다.

coevolution이 3차원 structural information을 주는 이유

MSA · 함께 달라지는 두 열

	i = 20		j = 80
query	D	...	K
homolog1	E	...	R
homolog2	K	...	D
homolog3	R	...	E

Trained model:
위치 관계 inference

Structure · 근접 후보



호환되는 residue 조합이
homologous sequences에 남을 수 있음

sequence에서 60칸 떨어진 위치도
접하면 가까워질 수 있음

contact를 유지하는 선택이 residue 조합을 연결할 수 있으므로, MSA의 coevolution signal은 3차원 배치의 단서가 됩니다.

개념도·가상 예시: 100 residue 중 20·80열만 발체. 점선은 inference할 후보 관계이며 실제 예측 coordinates가 아닙니다.

Homology: 얼마나 닮았나보다 어디에서 왔나

용어	무엇을 말하나
Homology	common ancestor에서 유래한 관계
Identity	alignment에서 같은 residue의 비율
Similarity	정의한 점수 체계에서 유사한 residue 관계

homology는 common ancestor에서 유래했다는 관계

“70% homology” 대신 “정의한 alignment에서 70% identity”라고 표현

Ortholog와 paralog: 갈라진 사건을 묻는다

관계	기준 사건	기억할 점
Ortholog	speciation (S)	function identity를 보장하지 않음
Paralog	gene duplication (D)	같은 species 또는 다른 species에 존재


MRCA (most recent common ancestor): 두 gene이 처음 만나는 ancestor

species 이름·sequence similarity·function의 같고 다름만으로 정하지 않음


Species tree와 gene tree는 다른 질문

교육용 가상 예시

Species tree



Gene tree



S = speciation, D = gene duplication


A와 B는 species 이름; A_g1 등은 gene 이름

Species tree: species들의 분기 관계

Gene tree: 특정 gene family의 계보와 gene duplication·loss

예제 1: speciation보다 먼저 gene duplication되었다면

교육용 가상 phylogenetic tree: gene duplication → speciation



D에서 1번·2번 gene lineage가 먼저 나뉨


두 S는 같은 A-B speciation을 각 gene lineage에서 표시

A_1-B_1은 ortholog; A_1-A_2와 A_1-B_2는 paralog

같은 species 안의 관계와 다른 species 사이의 관계를 모두 확인

예제 2: speciation 뒤에 gene duplication되었다면

교육용 가상 phylogenetic tree: speciation → gene duplication



A lineage에만 gene duplication이 생긴 경우

A_1-B_1과 A_2-B_1은 각각 orthology 관계

A_1과 A_2는 서로 paralog

A_1과 A_2는 각각 B_1의 ortholog: B_1에 대한 co-orthologs

Paralog는 species 안에도, species 사이에도 있다


관찰 또는 용어	해석 기준
Within-species paralog	같은 species의 두 gene; ancestor gene duplication 시점은 별도 확인
Between-species paralog	다른 species의 두 gene; common ancestor 노드는 D
Inparalog / outparalog	기준 speciation 뒤 / 앞의 gene duplication에서 유래

“같은 species이면 paralog, 다른 species이면 ortholog”는 불완전한 규칙

In-/out-paralog는 비교하는 speciation 시점에 대한 상대적 용어

gene loss: 남은 하나끼리 비교하면 생기는 착시

교육용 가상 phylogenetic tree: gene duplication 뒤 서로 다른 사본 loss



현재 관찰되는 gene은 A_1과 B_2

현재 사본 수와 과거 분기 사건을 구분


각 species에 한 개씩 남았어도 일대일 ortholog라는 보장은 없음

다른 species의 sequence·gene tree·주변 gene 정보가 판별에 도움


활동지 1 · Gene tree에서 ortholog-paralog 판정

상황 A: $D \rightarrow S$ / 상황 B: $S \rightarrow D$

A: duplication $\rightarrow$ speciation



B: speciation $\rightarrow$ duplication



문제 · 근거와 함께 답하세요

① 상황 A: H_A-M_A, H_A-H_B, H_A-M_B의 관계와 분기 사건은?

② 상황 B: H1-H2, H1-M, H2-M의 관계는? M에 대한 H1-H2의 관계는?

③ 가장 비슷한 두 sequence는 반드시 ortholog일까요? 빠진 정보는?

H=사람 lineage, M=생쥐 lineage. 가상 이력이며 가지 길이는 시간-similarity를 뜻하지 않습니다.

정답·해설 · 상황 A: gene duplication 뒤 speciation

비교할 gene 쌍	처음 만나는 사건	관계
H_A-M_A	speciation S	Ortholog
H_A-H_B	gene duplication D	Paralog
H_A-M_B	gene duplication D	Paralog

두 gene에서 ancestor 쪽으로 거슬러 올라가 처음 만나는 노드를 찾습니다. 그 사건이 S인지 D인지로 판정합니다.

H_A-M_B는 서로 다른 species에 있어도 paralog입니다. species 이름이나 sequence similarity만으로 관계를 정하지 않습니다.

정답·해설 · 상황 B와 sequence similarity의 한계

상황 B의 비교	처음 만나는 사건	관계
H1-H2	gene duplication D	Paralog
H1-M / H2-M	speciation S	두 쌍 모두 ortholog

H1·H2는 M에 대한 co-orthologs입니다. H1과 H2 서로의 관계는 paralog입니다.

③ 높은 identity만으로 orthology를 확정할 수 없습니다. gene tree·species tree와 gene duplication·speciation·loss 이력에 대한 근거가 필요합니다.

Ortholog여도 function이 완전히 같지는 않다

알 수 있는 것	추가 확인할 것
Orthology / paralogy	기원과 분기 사건
높은 sequence identity	alignment 길이·domain 구성·evolutionary relationship
비슷한 predicted structure	substrate·activity·expression·실험 조건

evolutionary relationship은 function inference의 근거이며 function 실험의 대체물이 아님

최고 similarity hit 하나만으로 orthology 또는 function을 확정하지 않음

gene family에서 MSA로: 대응 위치를 제안한다

Multiple sequence alignment(MSA): 여러 homologous sequence의 대응 위치를 alignment

alignment는 비교를 위한 가설이며 모든 열이 정확하다는 보장은 없음

너무 먼 sequence·부분 sequence·다른 domain 구성은 별도 점검

MSA 읽기: 행·열·query·gap

교육용 가상	sequence: 실제 protein 아님
column	123456789
query	AC-DEFGHI
seq_A	ACQDEYGHI
seq_B	AC-NEFG-I
seq_C	AS-DEF-HI

4행 × 9열; query의 실제 길이는 8 residue

3열의 Q는 query에 대응 residue가 없는 insertion 위치

행(row)은 sequence, 열(column)은 대응 위치, “-”는 gap

Query는 이번 분석의 기준 sequence; 항상 ancestor sequence라는 뜻은 아님

Gap 하나가 residue number를 바꾼다

교육용 가상 sequence

column	1	2	3	4	5	6	7	8	9
query	A	C	-	D	E	F	G	H	I
query residue	1	2	-	3	4	5	6	7	8

alignment 4열 = query의 D3

원래 query sequence: ACDEFGHI

alignment 열 번호와 query residue number를 구분해서 기록

Gap만으로 insertion·deletion의 evolution 방향을 확정할 수 없음

FASTA: 이름 줄과 sequence 줄부터 읽기

```
>query_synthetic    educational example  
ACDEFGHI  
>seq_A_synthetic    educational example  
ACQDEYGHI
```

두 sequence의 실제 길이는 8과 9

이 텍스트는 alignment 전의 교육용 가상 FASTA

“>”로 시작하는 줄은 이름·설명, 다음 줄은 sequence

여러 FASTA sequence가 있다고 자동으로 MSA가 되는 것은 아님

A3M: 대문자와 소문자는 서로 다른 역할

교육용 가상 A3M

```
>query
```

```
ACDEFGHI
```

```
>seq_A
```

```
ACqDEYGHI
```

```
>seq_B
```

```
ACNEFG-I
```

seq_A: q는 insertion, Y는 대응 열의 substitution

겉보기 문자 수가 달라도 같은 match 열을 표현 가능

대문자 = match 상태의 residue; 소문자 = insertion residue; “-” = deletion 표시

Match는 query와 같은 amino acid이라는 뜻이 아님

활동지 2 · 전체 A3M을 읽고 답하기

실습용 A3M · 전체 입력

```
>query
ACDEFGHIKLMN
>example_A1 group=A
ACDEFGHIKLMN
>example_A2 group=A
ACDeeEFGHIKLMN
>example_A3 group=A
ACDE-GHIKLMN
>example_B1 group=B
ACDEYGHIXLXN
>example_B2 group=B
ACDttEYGHIXL-N
>example_B3 group=B
AC-EYGHIXLXN
```

문제 · 근거와 함께 답하세요

- ① Query 포함/제외 행 수와 alignment 열 수는?
- ② ee의 위치는? 대문자화하면 생기는 오류는?
- ③ A3의 gap·B1의 X: 열 번호와 뜻은?
- ④ 행을 복제하면 독립 evolutionary information도 늘어나나요?

허구 자료이며 실제 예측 target이 아닙니다. A/B는 임의 라벨입니다. 헤더 설명은 축약했고 sequence는 그대로입니다.

정답·해설 · 활동지 2쪽 · A3M의 행과 열

세는 대상	계산 또는 확인	정답
Query 행	query 헤더 1개	1행
Homolog 행	$A1 \cdot A2 \cdot A3 + B1 \cdot B2 \cdot B3$	6행
전체 raw depth	query 1 + homolog 6; 동일한 A1도 포함	7행
alignment 열	각 행의 소문자 제외; 대문자·gap 포함	12열

세는 순서: “>” 헤더별 sequence 수 → query 구분 → 소문자를 제외한 alignment 열.
흔한 오류: 복제 행 증가 = 정보 증가. diversity·coverage·정의를 기록한 Neff도 확인.

정답·해설 · 활동지 2쪽 · ee, gap, X의 차이

교육용 가상 A3M 발취

column	123456789012
query	ACDEFGHIKLMN
A2 raw	ACDeeEFGHIKLMN
A2 match	ACDEFGHIKLMN
A3	ACDE-GHIKLMN
B1	ACDEYGHIXLXN

ee = D(3열) 뒤, E(4열) 직전 insertion; 원문 14글자 / alignment 12열

“A2 match”는 소문자를 제외해 읽는 보조 표시; 원본 편집 지시가 아님

A3의 5열 “-”는 대응 residue가 없는 gap; B1의 11열 X는 residue 정체 미상·가림.

흔한 오류: ee를 대문자화해 2열 추가, 또는 X를 gap으로 바꾸기.

Coverage와 identity: 분모를 함께 적는다

교육용 정의	계산
Query coverage	짜지어진 query residue 수 / query 길이
Identity	같은 residue 수 / 양쪽에 residue가 있는 비교 위치 수
보고 예	identity 80%, coverage 25%; 각 분모도 기록

Coverage: query의 어느 정도를 비교했는가?

Identity: 비교한 위치 중 어느 정도가 같은 residue인가?

바로 실습 · Coverage와 identity 계산

교육용 가상 sequence

query ACDEFGHI

A ACDE----

B ACNEYGHI

A의 끝부분 gap은 query 위치를 덮지 않음

Coverage와 identity의 분모를 각각 적기

Query 길이 8; A와 B 각각 coverage와 identity를 계산

분모는 앞 장의 교육용 정의를 사용

전체 query를 설명할 때 어떤 차이를 함께 보고해야 하는가?

정답·해설 · Coverage와 identity · 분모부터 쓰기

가상 hit	Coverage: 짝지어진 수 / 8	Identity: 동일 수 / 비교 수
A: ACDE----	4/8 = 50%	4/4 = 100%
B: ACNEYGHI	8/8 = 100%	6/8 = 75%
차이의 근거	A: 뒤 4곳 gap; B: gap 없음	A: 4곳 동일; B: D/N·F/Y 다름

계산 순서: 짝지어진 위치 수 → 같은 residue 수 → 지표별 분모에 대입.

흔한 오류: A의 identity를 4/8로 계산. 여기서는 gap 없는 비교 4곳이 분모.

Conservation: 한 열에서 무엇이 유지되는가?

교육용 가상 sequence

seq_1 ACDK

seq_2 ASDK

seq_3 ACEK

seq_4 ASER

열 1234

conservation은 한 열의 residue distribution에 대한 질문

“모두 같다”와 “서로 독립적인 근거가 많다”를 구분

한 위치의 residue distribution을 읽는 것이 conservation

Conserved 위치는 structural·functional constraint의 후보이며 원인은 추가 확인

conservation·covariation·coevolution은 서로 다른 질문


개념	무엇을 묻는가?	예
Conservation	한 위치에서 어떤 residue가 유지되는가?	위치 i가 대부분 D
Covariation	두 위치의 조합이 독립적 distribution과 다른가?	i가 D이면 j가 K인 경향
Coevolution	위치들의 evolution가 어떻게 서로 의존하는가?	structural·functional constraint를 함께 만족

이 강의에서는 관찰한 통계 패턴과 그 패턴의 evolutionary 설명을 구분

Ortholog/paralog는 행 사이의 관계; residue covariation은 열 사이의 관계


contact를 유지하는 선택이 coevolution을 만들 수 있다

compatible pair A




반대 charge 조합
이 가정에서는 유리

compatible pair B



다른 residue라도
반대 charge 조합 유지

incompatible pair



같은 charge 조합
이 가정에서는 덜 유리

한 위치의 변화가 다른 위치의 허용 residue를 바꿀 수 있다

이런 제약이 homologous sequence의 조합 패턴에 남을 수 있어, evolutionary information로 contact하는 위치 쌍을 추정할 수 있습니다.

개념도·가상 예시. 가까운 두 위치의 반대 charge가 유리하다고 가정. 색=i/j 위치, -/+ = side chain charge. evolution 순서 아님.

두 열의 빈도와 조합 빈도를 따로 센다

8행의 가상 자료	j = D	j = K	행 합계
i = D	0	4	4
i = K	4	0	4
열 합계	4	4	8

관찰: $P(D_i, K_j) = 4/8 = 1/2$

독립이라면: $P(D_i) \times P(K_j) = 1/2 \times 1/2 = 1/4$

이 가상 자료에는 statistical dependence이 있음; 그 원인은 아직 모름

활동지 3 · 두 열의 joint frequency 계산

가상 조합	자료 P: 8행	대조 자료 Q: 8행
D-D	0	2
D-K	4	2
K-D	4	2
K-K	0	2

D=Asp, K=Lys; i·j는 같은 protein의 두 alignment 위치입니다. 두 자료는 가상입니다.

① 각 자료의 $P(D_i)$, $P(K_j)$, $P(D_i, K_j)$ 를 계산하고 독립일 때의 곱과 비교하세요.

단일 열의 빈도·conservation만으로 두 자료를 구별할 수 있나요?

정답·해설 · 같은 conservation, 다른 joint distribution

계산·판정	자료 P	대조 자료 Q
한 열씩 센 marginal frequency	$P(D_i) = 4/8 = 1/2$ $P(K_j) = 4/8 = 1/2$	$P(D_i) = 4/8 = 1/2$ $P(K_j) = 4/8 = 1/2$
함께 나타난 D-K 빈도	$P(D_i, K_j) = 4/8 = 1/2$	$P(D_i, K_j) = 2/8 = 1/4$
독립일 때 기대 빈도	$(1/2) \times (1/2) = 1/4$	$(1/2) \times (1/2) = 1/4$
경험적 distribution의 판정	관찰 $1/2 \neq$ 기대 $1/4$ 두 열이 독립적이지 않음	네 조합이 모두 각각 $1/4$ 이 표의 두 열은 독립

한 열의 빈도·conservation은 같으므로 구별 불가. 두 열의 조합까지 보아야 합니다.

phylogenetic effects와 indirect association도 covariation을 만듭니다. 이 계산만으로 direct contact를 입증하지는 못합니다.

휴식 · 10분

10분 뒤 다시 시작합니다.

다음: covariation 패턴을 gene lineage와 함께 해석하기

Ortholog를 모아도 common ancestor는 남아 있다

질문	Ortholog를 모으면?
다른 gene duplication lineage의 혼합인가?	대상 lineage를 맞추는 데 도움이 됨
각 sequence는 독립 관측인가?	아님: 가까운 종은 ancestor의 패턴을 공유
모든 위치가 같은 제약을 받나?	보장 없음: lineage별 function·환경 차이도 가능

Ortholog 관계는 비교할 gene lineage를 정리하는 데 도움

후손 100개의 같은 조합 ≠ 독립적인 compensatory substitution 100회

phylogenetic tree의 여러 가지에서 반복되었는지는 따로 평가해야 함

Paralog 혼합은 lineage 차이를 함께 섞는다

같은 MSA를 보는 방법	확인할 것
모든 homologous sequence를 합침	관찰한 조합이 subfamily 이름을 구별하는가?
gene duplication lineage별로 나눔	각 lineage 안에도 두 위치의 변화가 있는가?
lineage를 제외함	혼합 효과와 함께 유용한 diversity도 잃는가?

두 subfamily가 각각 다른 residue를 선호하면 혼합 후 covariation이 생길 수 있음

Ortholog만 남기는 규칙 대신 분석 목적·alignment·lineage 구성을 함께 점검

활동지 3 · lineage를 나누고 evolutionary history 해석

가상 sequence: 각 이름이 한 행	i	j
A_H, A_M, A_R, A_F	모두 D	모두 K
B_H, B_M, B_R, B_F	모두 K	모두 D

가정: A/B gene duplication → H/M/R/F 네 species로 분화. 추가 gene duplication·loss 없음. D=Asp, K=Lys.

- ② A_H-A_M, A_H-B_M의 관계는? 각 lineage 내부에 variation가 남나요?
- ③ 8행은 독립 compensatory change 8회 또는 direct contact의 증거인가요? common ancestor 효과는?
- ④ Ortholog만 모으면 phylogenetic effects가 사라지나요? 더 필요한 근거를 쓰세요.

정답·해설 · lineage 차이와 coevolution을 구분

비교	정답·관찰	판정 근거
A_H-A_M	Ortholog	MRCA: speciation (S)
A_H-B_H A_H-B_M	모두 paralog	MRCA: gene duplication (D)
각 lineage 내부	A: D-K만 / B: K-D만	두 열 모두 variation 없음
합친 8행	D-K 4행 / K-D 4행	Covariation이 A/B 구분과 겹침

8행은 독립 compensatory substitution 8회가 아닙니다. Ancestor에게서 같은 조합을 물려받았을 수 있습니다.

④ Ortholog에도 phylogenetic effects가 남습니다. Alignment·tree·독립 가지의 변화와 structure·실험 근거로 direct contact를 확인합니다.

complex에서는 어떤 sequence끼리 짝 지었는가?

분석	한 행의 의미	핵심 확인
protein 내부	한 homologous protein의 sequence	같은 sequence의 위치 i와 j
protein 사이	protein P sequence Q sequence	P의 위치 i와 Q의 위치 j
같은 species에 여러 paralog	P1/P2와 Q1/Q2 존재	P1의 상대가 Q1인가 Q2인가?

Paired MSA는 서로 다른 protein의 sequence를 같은 행에 대응시킴

같은 species에 있다는 사실만으로 실제 binding partner를 확정할 수 없음

함께 변한다고 모두 직접 연결된 것은 아니다

접근	무엇을 하는가?
covariation·MI	두 열의 관찰 distribution이 독립적인지 비교
DCA	여러 열을 함께 model화해 직접·간접 통계 효과를 구분
AlphaFold	training한 model으로 sequence·MSA 등 정보를 통합해 structure prediction

i-k와 k-j 관계만 있어도 i-j에 indirect correlation이 생길 수 있음

추정한 coupling도 실제 contact-mechanism의 자동 증명이 아님

Raw depth와 Neff: 행 수와 diversity는 다르다

교육용 reweighting 예	Raw depth	weight 합
완전히 동일한 sequence 100개	100	$100 \times 1/100 = 1$
서로 기준 이상 유사한 쌍이 없는 100개	100	$100 \times 1 = 100$
실제 MSA	행 수를 기록	정의·similarity 기준·coverage도 기록

Raw depth는 sequence 행 수; 같은 sequence가 많아도 그대로 증가

Neff는 redundancy·similarity를 반영하는 지표이며 계산법을 반드시 명시

AlphaFold2와 AlphaFold3

항목	AlphaFold2 family	AlphaFold3
주요 입력	protein sequence·MSA·template	protein·핵산·ligand 등
coordinates 생성	structure 모듈과 recycling	Diffusion 기반 생성
이 강의에서 역할	MSA 조작의 주요 실습 도구	기본 예측과 확장 적용 비교
해석 원칙	여러 예측을 만들고 검증	별도 검증 후 기법 적용

이 강의의 MSA 조작 사례는 주로 AF2에서 검증되었습니다.

웹 서버와 로컬 실행

웹 서버: sequence와 molecule를 입력해 빠르게 시작

로컬 AF3: JSON으로 custom MSA·template 지정

MSA 조작 실습: custom A3M을 받는 ColabFold 활용

실제 예측에는 model 설치·계산 자원이 필요

Custom MSA의 기본 조건

첫 번째 sequence는 예측할 query와 일치

alignment 열은 query의 위치와 대응

A3M의 소문자는 insertion, 대문자·gap은 alignment 열

비교할 때 query·template·model 버전을 함께 기록

ColabFold 1 · 접속과 실습 준비

아래 URL을 브라우저 주소창에 붙여 넣고 Google 계정으로 로그인
필요하면 File → Save a copy in Drive로 개인 사본 저장
예제 파일: examples/calmodulin_P0DP23.fasta · 다운로드는 46번
이 수업에서는 protein 한 사슬, 149개 amino acid을 입력

<https://colab.research.google.com/github/sokrypton/ColabFold/blob/main/AlphaFold2.ipynb>

ColabFold 2 · GPU와 노트북 실행 방식

Runtime → Change runtime type → GPU 선택 → Save

한국어 메뉴: 런타임 → 런타임 유형 변경

코드 셀은 왼쪽 ▶로 실행하며, 위에서 아래로 이어집니다.

GPU를 할당받지 못하면 교사 결과·오프라인 활동으로 진행

ColabFold 3 · sequence와 기본 조건 입력

화면 항목	이번 실습의 입력	의미
query_sequence	Human CALM1 · 149 aa	예측할 protein
jobname	calm_baseline	결과를 구분할 이름
num_relax / template_mode	0 / none	처음에는 template 없이
msa_mode	mmseqs2_uniref_env	검색으로 기본 MSA 생성

FASTA 다운로드: 아래 URL → calmodulin_P0DP23.fasta로 저장

제목(>) 줄 제외 → query_sequence에 sequence만 입력 → length 149 확인

<https://rest.uniprot.org/uniprotkb/P0DP23.fasta>

ColabFold 4 · Run all과 계산 진행 확인

Advanced settings: model_type=alphafold2_ptm, num_recycles=3

Sample settings: max_msa=auto, num_seeds=1, use_dropout 해제

Runtime → Run all / 런타임 → 모두 실행

설치 → MSA 검색 → Run Prediction → 결과 표시 순서 확인

ColabFold 5 · 결과와 MSA 다운로드

Display 3D structure에서 rank_num과 per-residue 색 확인

Plots에서 MSA coverage·pLDDT·PAE 확인

Package and download results의 실행 버튼으로 결과 ZIP 저장

ZIP의 .a3m·structure .pdb·설정/로그를 함께 보관

실습 확인·해설 · ColabFold 기본 실행

확인할 것	기대되는 상태	이유·오류 확인
sequence 입력	Header를 뺀 CALM1 sequence, length 149	다른 길이면 제목·다른 sequence·중복 붙여넣기부터 확인
설정 확인	jobname=calm_baseline, 지정 model·template 조건	ZIP의 설정·로그와 입력을 함께 보관해야 재현 가능
파일 확인	다운로드 ZIP에 .a3m·.pdb·설정/로그	MSA 생성·예측·다운로드가 어디까지 끝났는지 확인
그림 읽기	pLDDT·PAE·MSA coverage를 각각 찾기	각 지표의 의미는 다음 설명에서 확인

예측 coordinates와 점수에는 고정 정답이 없습니다. seed·GPU·서버·버전에 따라 결과가 달라질 수 있습니다.

GPU 대기로 완료되지 않았다면 성공으로 기록하지 말고 마지막 실행 단계와 오류를 기록합니다.

IDDT · reference structure의 주변 거리가 얼마나 보존되었나?

IDDT = local Distance Difference Test · reference structure와 비교하는 accuracy 점수

원 지표는 atom 단위 평가. 여기서는 AF2의 per-residue IDDT-C α 를 사용

- ① reference structure에서 중심 C α 의 15 Å 미만 neighbor를 선택
 - ② 거리 오차 $|\text{predicted distance} - \text{reference distance}|$ 를 0.5·1·2·4 Å로 검사
- 전체 structure를 겹칠 필요는 없지만, 대응 residue와 reference coordinates는 필요

바로 실습 · 네 거리쌍의 IDDT 계산하기

중심 residue i와 네 neighbor

Pair	Ref. Å	Pred. Å	Abs. error Å	Pass / 4
a	4.0	4.2	—	—
b	7.0	7.8	—	—
c	10.0	11.5	—	—
d	14.0	17.0	—	—

문제 · 근거와 함께 답하세요

- ① 각 쌍의 $|\text{predicted distance} - \text{reference distance}|$ 를 구하세요.
- ② 오차 $< 0.5, < 1, < 2, < 4$ Å를 각각 검사해 통과 수를 채우세요.
- ③ $\text{IDDT}_i = \text{통과 수 합} / 16 = \underline{\hspace{1cm}}$.
100점 척도로는 $\underline{\hspace{1cm}}$ 입니다.

Ref.=reference distance, Pred.=predicted distance. 가상 Cα pairs이며 reference distance는 모두 15 Å 미만입니다.

정답·해설 · 네 neighbor의 거리 오차를 네 번 채점

Pair	reference distance (Å)	predicted distance (Å)	absolute error (Å)	통과 수 / 4
a	4.0	4.2	0.2	4 / 4
b	7.0	7.8	0.8	3 / 4
c	10.0	11.5	1.5	2 / 4
d	14.0	17.0	3.0	1 / 4

중심 residue i의 가상 neighbor 4개만 사용. 오차 < 0.5, < 1, < 2, < 4 Å를 각각 검사

오차 0.8 Å는 1·2·4 Å 검사를 통과합니다. 네 검사는 겹칩니다.

$$IDDT_i = (4 + 3 + 2 + 1) / (4 \times 4) = 0.625 \rightarrow 100\text{점 척도로 } 62.5$$

바로 실습 · predicted distance가 더 멀어지면?

d의 predicted distance만 19 Å로 변경

Pair	Ref. Å	Pred. Å	Abs. error Å	Pass / 4
a	4.0	4.2	0.2	4
b	7.0	7.8	0.8	3
c	10.0	11.5	1.5	2
d	14.0	19.0	_____	_____

문제 · 근거와 함께 답하세요

- ① d의 absolute distance error와 네 검사 중 통과 수는?
- ② d는 neighbor 계산에 [포함 / 제외]되나요? 어느 거리를 기준으로 판단하나요?
- ③ 새 IDDT_i는 [9/16 또는 9/12]인가요? 100점 척도로는 _____입니다.

Ref.=reference distance, Pred.=predicted distance. 가상 Cα pairs이며 reference distance는 모두 15 Å 미만입니다.

정답·해설 · 오차가 커져도 neighbor는 그대로

Pair	absolute error (Å)	통과한 기준: 오차 < ... Å	통과 수
a	$ 4.2 - 4 = 0.2$	$0.5 \cdot 1 \cdot 2 \cdot 4$	4
b	$ 7.8 - 7 = 0.8$	$1 \cdot 2 \cdot 4$	3
c	$ 11.5 - 10 = 1.5$	$2 \cdot 4$	2
d	$ 19 - 14 = 5$	없음: 4 Å 기준도 실패	0

새 IDDT_i = $(4 + 3 + 2 + 0) / (4\text{쌍} \times 4\text{기준}) = 9/16 = 0.5625 \rightarrow 56.25\text{점}$

d의 reference distance 14 Å는 15 Å 미만: 계속 포함합니다. 빼면 분모가 줄어 점수가 부풀려집니다.

pLDDT가 나온 과정 · 채점한 IDDT를 training target으로

AF2 training 단계	사용 정보	만드는 것
① structure prediction	sequence·MSA 등	예측 coordinates + per-residue internal representation
② 정답 점수 계산	예측 coordinates + training용 reference coordinates	실제 계산한 per-residue IDDT-C α
③ confidence training	internal representation → confidence head	IDDT의 50개 bin에 대한 distribution

예: 계산한 IDDT 0.625 → [0.62, 0.64) bin0] training target

예측 distribution이 정답 bin을 맞히도록 training합니다(cross-entropy).

reference coordinates는 채점·지도에 사용하며, confidence head에 정답으로 입력하지 않습니다.

바로 실습 · IDDT 계산과 pLDDT inference 구별하기

세 bin의 probability-weighted mean

bin center c	확률 p	$p \times c$
0.49	0.10	_____
0.69	0.20	_____
0.89	0.70	_____

문제 · 근거와 함께 답하세요

- ① IDDT를 직접 계산할 때와 pLDDT를 inference할 때, 어느 쪽에 reference structure가 필요한가요?
- ② pLDDT 90은 coordinates가 정확할 확률 90% 또는 상태의 population 90%인가요?
- ③ $100 \times \sum(p \times c) = \underline{\hspace{2cm}}$. 최다 확률 bin의 중심 $\times 100$ 과 같은가요?

AF2의 50개 중심 중 세 개를 사용한 가상 근사입니다. 나머지 확률은 0으로 단순화했습니다.

정답·해설 · Reference structure와 pLDDT 계산

bin center c_k	예측 확률 p_{ik}	$p_{ik} \times c_k$
0.49	0.10	0.049
0.69	0.20	0.138
0.89	0.70	0.623

- ① reference structure: IDDT 직접 계산에는 필요 / training된 pLDDT inference에는 불필요
- ② pLDDT 90은 coordinates가 정확할 확률 90%·state population 90%가 아닙니다.
- ③ 50 logits $\rightarrow$ softmax $\rightarrow 100 \times \sum(p \times c) = 81$; 최다 확률 bin만 고르면 89


pLDDT의 네 가지 색 · 숫자와 함께 읽기

점수 범위	보통의 표시색	해석의 출발점
$90 \leq \text{점수} \leq 100$	진한 파랑	매우 높은 local confidence
$70 \leq \text{점수} < 90$	하늘색	대체로 믿을 만한 골격
$50 \leq \text{점수} < 70$	노랑	낮은 confidence, 세부 해석 주의
$0 \leq \text{점수} < 50$	주황	매우 낮음, coordinates 해석을 보류

색은 confidence를 쉽게 보기 위한 표시입니다. 화면의 범례를 확인하세요.

구간 경계는 해석 지침이며, 특정 값에서 accuracy가 갑자기 바뀌지 않습니다.

평균 82.8점이 가리는 낮은 confidence 구간



가상 개념도(실제 예측 아님): A 1-5 / linker 6-7 / B 8-12

전체 평균 82.8 / A·B 각각 91.2 / linker 41.0

평균과 함께 per-residue 그래프·3D 색·관심 부위를 확인

바로 실습 · pLDDT 그래프에서 말할 수 있는 것

가상 per-residue pLDDT (0–100)

구간	위치	각 위치의 pLDDT
A	1–5	94, 93, 91, 90, 88
linker	6–7	43, 39
B	8–12	86, 92, 94, 93, 91

문제 · 근거와 함께 답하세요

- ① 특히 조심해서 해석할 위치 두 곳과 점수를 쓰세요.
- ② 전체 평균 82.8이면 모든 위치를 믿을 수 있나요?
- ③ A와 B의 relative orientation까지 확정할 수 있나요?
- ④ 낮은 값만으로 disorder·fast motion을 확정할 수 있나요?

domain 개념을 12개 위치로 축약한 가상 자료. 실제 protein·inference 결과가 아니며 A3M 예제와 별개입니다.

정답·해설 · 평균으로 낮은 confidence 구간을 가리지 않기

질문	정답	왜 그렇게 해석하나요?
특히 주의할 위치	6번 43 · 7번 39	linker의 local confidence가 낮습니다.
평균 82.8이면 모두 신뢰?	아니요: $994/12 \approx 82.8$	다른 높은 값들이 linker 평균41.0을 가립니다.
A·B의 relative orientation 확정?	아직 알 수 없습니다.	각 부분의 pLDDT는 domain 간 배치 점수가 아닙니다.
disorder·fast motion 확정?	가능한 설명일 뿐입니다.	정보 부족도 가능하며 motion rate는 점수로 알 수 없습니다.

A·B 평균은 각각 91.2: local structure를 검토할 근거가 있습니다. relative placement는 PAE도 읽어야 합니다.

점수가 같은 두 부분이 같은 모양이라는 뜻은 아닙니다. 여기의 숫자는 설명용 가상 점수입니다.

PAE · 기준을 고정하면 다른 위치는 얼마나 불확실할까?

PAE = Predicted Aligned Error, 예측 alignment 오차

PAE(i,j): j의 local coordinate frame를 맞췄다고 할 때 i의 expected positional error

단위 Å, 낮을수록 상대 위치를 더 확신 / 이 예제: 행 i·열 j

두 residue 사이 거리나 두 실물 structure에서 측정한 RMSD와 다릅니다.

PAE 표 읽기 · domain 내부와 domain 사이

i ↓ / j →	A3	A4	B9	B10
A3	0	1	18	20
A4	1	0	19	21
B9	24	23	0	2
B10	22	24	2	0

가상 예제의 3·4·9·10번만 선택한 4×4 표 / 단위 Å

행 = 평가할 i / 열 = alignment anchor j / domain 사이 두 방향 모두 확인

교육용 색: 진한 청록 0–2 Å / 옅은색 18–24 Å (낮을수록 더 신뢰)

두 점수 함께 읽기 · 부분의 모양과 relative placement

높은 pLDDT + 낮은 내부 PAE → 각 domain 내부 structure를 더 신뢰

높은 domain 사이 PAE → 두 domain의 relative placement는 불확실

flexibility·disorder는 가능한 설명이며, 점수만으로 확정하지 않음

낮은 PAE도 실제 binding·state population·transition rate를 증명하지 않음

바로 실습 · 같은 pLDDT, 다른 PAE

조건 P의 PAE (Å)

i ↓ / j →	A3	A4	B9	B10
A3	0	1	18	20
A4	1	0	19	21
B9	24	23	0	2
B10	22	24	2	0

문제 · 근거와 함께 답하세요

- ① $PAE(A3, B9) = \text{___} \text{Å}$, $PAE(B9, A3) = \text{___} \text{Å}$. 각 기준은? residue 사이 거리인가요?
- ② A/B 내부와 A-B 사이를 비교하세요. 높은 per-region pLDDT와 큰 구간 간 PAE는 무슨인가요?
- ③ Q는 pLDDT가 같고 표의 대각선 밖 PAE가 모두 1–3 Å입니다. 무엇을 더 확신하나요? binding·상태 존재·population도 확정되나요?

전체 12×12 중 3·4·9·10의 가상 부분표. 행 i=평가 대상, 열 j=alignment 기준. A/B 평균 pLDDT는 각각 91.2.

정답·해설 · PAE의 기준과 평가 대상을 나누기

읽은 칸: 행 i·열 j	alignment anchor j	평가 대상 i	expected positional error
PAE(A3, B9)	B9의 local coordinate frame	A3	18 Å
PAE(B9, A3)	A3의 local coordinate frame	B9	24 Å

B9를 기준으로 보면 A3의 예상 오차는 18 Å; A3을 기준으로 보면 B9는 24 Å입니다.

local coordinate frame이 달라 두 방향 값은 달라도 됩니다. A3-B9 사이의 실제 거리를 읽은 것이 아닙니다.

정답·해설 · Q는 제시된 relative placement를 더 확신한다

비교할 정보	P	Q	허용되는 해석
pLDDT	원래 점수	P와 동일	local confidence는 달라지지 않음
내부 PAE: 대각선 밖	1-2 Å	1-3 Å	둘 다 제시된 내부 배치를 확신
A-B 사이 PAE	18-24 Å	1-3 Å	Q가 이 위치쌍의 relative placement를 더 확신
상태의 실제 비율	제공되지 않음	제공되지 않음	pLDDT·PAE로 population을 계산할 수 없음

모순 아님: pLDDT는 local 모양, PAE는 relative placement의 confidence입니다. 제시한 A-B 배치는 Q가 더 확신합니다.

낮은 PAE로 binding·특정 상태의 존재·population을 확정하지 못합니다. 생략한 위치는 별도로 확인합니다.

휴식 · 10분

10분 뒤 다시 시작합니다.

다음: custom MSA와 depth·clustering·masking 실습

ColabFold 6 · Custom MSA 업로드

새 jobname 입력 · query_sequence는 동일하게 유지

MSA options에서 msa_mode를 custom으로 선택

Runtime → Run all → 업로드 창에서 .a3m 한 개 선택

첫 query가 CALM1 149 aa인지 확인하고 결과 ZIP 저장

실습 확인·해설 · Custom MSA 입력

확인할 것	기대되는 상태	이유·오류 확인
Query	원래 CALM1 sequence와 첫 query가 일치	길이149만 같아서는 부족: residue sequence도 대조
입력 모드	msa_mode=custom, 선택한 .a3m 한 개	다른 조건 파일을 넣었으면 비교 조건이 바뀜
기록	새 jobname·파일명·MSA 행 수·설정	같은 query를 유지하고 무엇을 바꿨는지 명시
결과 확인	새 ZIP에서 structure·점수·설정/로그 확인	structure 변화가 없어도 정상적인 비교 결과

실제 실습에는 CALM1에서 얻은 MSA를 사용합니다. 12열 가상 A3M은 파일 읽기 연습용입니다.

AF3에서 custom MSA 지정

```
"protein": {  
  "id": "A",  
  "sequence": "<full query sequence>",  
  "unpairedMsaPath": "target.a3m",  
  "pairedMsa": "",  
  "templates": []  
}
```

unpairedMsaPath: 직접 준비한 A3M

pairedMsa: monomer 실습에서는 빈 값

templates: template 비교 조건 고정

아래는 protein 항목의 형식 예시입니다.

실제 FASTA와 A3M을 사용한 완전한 JSON은 [examples/](#)에서 생성합니다.

한 번에 한 조건씩 비교

Baseline: 원본 MSA와 정해진 seed 목록

Depth: 행 수만 줄여 여러 번 sampling

Cluster: 비슷한 sequence 집단별 입력

Mask: 정해진 열의 정보만 가리는 조건

활동지 4 · 비교 조건을 설계하기

설계	조건 1	조건 2
A	Query Q / template 없음 / 5회	Query Q 일부 삭제 / template 있음 / 50회
B	Query Q / 전체 MSA / 10회	Query Q / 선택 MSA / 10회
B의 공통 조건	model·template·seed 집합	같이 유지

④ MSA 행 선택의 효과를 보려면 A/B 중 어느 설계가 더 공정한가요?

고정하거나 기록할 항목을 세 가지 이상 쓰고 이유를 설명하세요.

정답·해설 · 공정한 비교는 B

판단	정답과 이유
B를 선택	같은 query·각 10회: homolog 행 선택의 효과를 비교
A의 문제	query 삭제·template 추가·5→50회가 함께 변해 원인 구별 불가
고정할 것	query·model/weight·template·예측 seed 집합·recycle·생성 수
기록할 것	선택한 행 ID와 행 수 / 행 추출 seed와 MSA 검색 DB·날짜

전체 MSA control이 있어야 선택 MSA의 변화와 원래 예측 경향을 비교할 수 있습니다.

흔한 오류: seed 개수만 맞추거나, 더 많이 만든 쪽의 최고 점수만 비교하기.

기준 예측부터 기록한다

먼저 고정	변경 후보	함께 기록
Query·model 버전	MSA 행 또는 열	입력 파일·행 수
Template 조건	Seed·dropout	반복 수·실행 설정
structure 비교 구간	한 조건씩 비교	pLDDT·PAE·structure 차이

같은 protein의 입력 근거를 바꾸어 비교한다.

Query sequence·길이·번호를 먼저 고정한다.

한 번에 바꾸는 조건과 반복 횟수를 기록한다.

행을 줄인다: MSA subsampling

원래 MSA

query	ACDEFGHI
hom1	AC-EYGHI
hom2	ACDEFG-I
hom3	ACNEFGHI

선택한 MSA

query	ACDEFGHI
hom1	AC-EYGHI
hom3	ACNEFGHI

교육용 가상 alignment. Query 행은 유지하고, homolog 행의 일부를 택한다. 열과 query 길이는 유지한다.

행(row) = alignment에 포함된 sequence 하나

Query는 남기고 homolog 행 일부를 선택한다.

행 수 감소는 정보 감소와 diversity 변화를 함께 만든다.

활동지 4 · Depth를 줄이고 query 확인

원본 MSA와 선택 조건

ID / group	A3M sequence
query	ACDEFGHIKLMN
A1 / A	ACDEFGHIKLMN
A2 / A	ACDeeEFGHIKLMN
A3 / A	ACDE-GHIKLMN
B1 / B	ACDEYGHIXLXN
B2 / B	ACDttEYGHIXL-N
B3 / B	AC-EYGHIXLXN

```
# depth=4, seed=7
python3 msa_lab.py --depth 4 --seed 7 \
  --out runs/student01
```

문제 · 근거와 함께 답하세요

① Query와 A2·A3·B1만 남깁니다. 첫 행은 무엇이고 왜 유지하나요?

결과의 전체 행 수·homolog 행 수·alignment 열 수는?

원본과 비교해 잃거나 달라질 수 있는 정보는?

실행 위치: Alprediction/practice/ · 컴퓨터 없이도 왼쪽 입력에서 선택 행을 표시해 풀 수 있습니다.

정답·해설 · Query 포함 4행, alignment 12열

```
depth=4 / row-sampling seed=7
```

```
query          ACDEFGHIKLMN
```

```
example_A2     ACDeeEFGHIKLMN
```

```
example_A3     ACDE-GHIKLMN
```

```
example_B1     ACDEYGHIXLXN
```

선택 ID: query, example_A2, example_A3, example_B1


허구 실습 자료: ee는 insertion이므로 A2 원문 14글자, alignment 12열

원본 7행 → 4행: homolog는 6개에서 3개로 감소하며 query는 불변입니다.

빠진 A1·B2·B3의 정보 때문에 열별 빈도·coverage·조합 빈도가 달라질 수 있습니다.

흔한 오류: depth 4를 homolog 4개로 세기. 4행이 독립 evolution 사건 4개라는 뜻도 아닙니다.

논문 그림 읽기: 얇은 MSA의 효과와 한계



점 하나는 predicted structure 하나: 실험 structure와 비교한다.
MSA 깊이에 따라 structure distribution이 달라진 사례가 있다.
diversity 증가에는 잘못 접힌 structure도 섞일 수 있다.

[del Alamo et al., eLife \(2022\), Fig. 1A \(발체\)](#)

[CC BY 4.0](#)

ColabFold 7 · 화면에서 MSA depth 비교

화면 항목	비교 A	비교 B
jobname	calm_depth32	calm_depth64
msa_mode	custom · 동일 A3M	custom · 동일 A3M
max_msa	32:64	64:128
고정 항목	같은 model·seed 수·template	같은 설정 유지


같은 A3M을 custom으로 재사용하고 max_msa만 변경
두 숫자는 주 MSA·extra MSA 한도이며 총 행 수가 아닙니다.

실습 확인·해설 · max_msa 두 조건 비교

확인할 것	기대되는 상태	이유·오류 확인
공통 입력	같은 CALM1 query와 custom A3M	Query·model·template·seed 조건도 맞추기
달라지는 값	calm_depth32: 32:64 calm_depth64: 64:128	주 MSA·extra MSA 두 한도만 변경
한도와 실제 행 수	한도96행/192행이라고 합산하지 않기	원본 행 수·redundancy·전처리 때문에 실제 사용 수는 다를 수 있음
결과 비교	pLDDT·PAE와 같은 atom/구간의 coordinates	값이 바뀌거나 structure가 열려야 성공인 것은 아님

두 ZIP과 설정을 보관합니다. 결과 차이가 보이면 동일한 seed 집합으로 반복해 reproducibility을 확인합니다.

AF-Cluster: sequence를 먼저 나누어 예측



MSA의 homolog를 sequence similarity로 나눈다.
각 sub-MSA를 별도로 AF2에 입력한다.
KaiB의 알려진 다른 fold를 탐색한 사례가 있다.

[Wayment-Steele et al., Nature \(2024\), Fig. 1d \(발췌\)](#)

[CC BY 4.0](#)

각 cluster에도 같은 query가 들어간다

Cluster A 입력

```
>query  
ACDEFGHI  
>hom1  
AC-EYGHI
```

Cluster B 입력

```
>query  
ACDEFGHI  
>hom3  
ACNEFGHI
```

교육용 가상 alignment. 두 입력의 query는 동일하고, 그 아래 homolog 조합만 다르다.

예측 대상 = query, 배경 정보 = homolog 집합

Cluster마다 query를 맨 앞에 다시 넣는다.

Cluster 대표 sequence로 query를 바꾸면 대상도 바뀐다.

활동지 4 · 두 그룹의 MSA를 직접 비교

그룹 라벨과 전체 입력

ID / group	A3M sequence
query	ACDEFGHIKLMN
A1 / A	ACDEFGHIKLMN
A2 / A	ACDeeEFGHIKLMN
A3 / A	ACDE-GHIKLMN
B1 / B	ACDEYGHIXLN
B2 / B	ACDttEYGHIXL-N
B3 / B	AC-EYGHIXLN

문제 · 근거와 함께 답하세요

② 동일 query와 A 행만, 동일 query와 B 행만 각각 묶으세요. 각 파일은 몇 행인가요?

각 그룹의 homolog 5열·11열 distribution을 비교하세요.

이 라벨 분리와 AF-Cluster의 차이는? Ortholog 집합·conformational state라 부를 수 있나요?

A/B는 편의를 위한 사전 라벨입니다. 활동지 3쪽의 evolutionary history를 주어진 조건으로 사용하지 않습니다.

정답·해설 · 그룹마다 residue distribution이 달라진다

파일	포함된 homolog	alignment 5열	alignment 11열
group_A	A1 · A2 · A3	F · F · -	M · M · M
group_B	B1 · B2 · B3	Y · Y · Y	X · - · X

두 파일 모두 동일 query + homolog 3행 = 4행입니다. 표의 distribution은 query를 제외했습니다.

허구 header의 A/B 라벨로 분리한 결과입니다. AF-Cluster 알고리즘을 실행한 것이 아닙니다.

A/B를 ortholog 집합이나 open/closed state로 부를 근거가 없습니다.

흔한 오류: 같은 행 수면 같은 정보량이라 생각하기. X는 불명 residue, -는 gap입니다.

sequence cluster는 thermodynamic 상태가 아니다

분류 질문	사용 정보	바로 알 수 없는 것
어떤 sequence가 닮았나?	sequence similarity	conformational state의 수
어떤 evolutionary relationship인가?	gene phylogeny·species phylogeny	상태별 population
어떤 structure가 다른가?	coordinates·contact·실험	transition rate

sequence similarity는 evolutionary relatedness과 function 차이를 섞어 답는다.

Ortholog / paralog 구분과 conformational state 구분은 다른 문제다.

Cluster 수·크기에서 상태 수·population을 바로 읽지 않는다.

2025년 논쟁: 비교 조건을 읽는다

자료	핵심 질문	읽을 때 확인
Nature 비판 (2025)	random sample보다 나은가?	target·sample 수·AF2 설정
JMB 응답 (2025)	evolutionary signal을 직접 시험했나?	control·추가 분석
우리 비교 설계	무엇 하나가 달랐나?	동일 조건·독립 평가

Matters Arising은 random sample 비교와 해석을 비판했다.

저자 응답은 비교 조건과 evolutionary signal의 역할을 재검토했다.

강의 결론: 같은 조건의 control과 독립 검증이 필요하다.

두 가지 clustering을 구별한다

단계	묶는 대상	목적
AF2 이전	MSA sequence 행	다른 입력 근거 만들기
AF2 이후	predicted structure 후보	redundancy 정리·대표 선택
실험 검증 이후	관찰된 상태	물리적 해석 뒷받침

입력 clustering: 예측 전에 sequence를 묶는다.

출력 clustering: 예측 후 structure를 묶는다.

많은 입력 cluster가 같은 structure를 만들 수도 있다.

열을 가린다: unknown X와 gap의 차이

원래		한 열을 X로 masking	
query	ACDEFGHI	query	ACDEFGHI
hom1	AC-EYGHI	hom1	AC-XYGHI
hom2	ACDEFG-I	hom2	ACDXFG-I
	↑		↑

교육용 가상 alignment. X = unknown residue, - = gap. Query 첫 행과 전체 alignment 열 수는 바꾸지 않는다.

열(column) = query의 alignment 위치에 대응

X는 종류를 모르는 residue, -는 alignment의 gap이다.

오늘 실습에서는 query를 보존한 채 정보만 가린다.

활동지 4 · A2의 5·7·10열을 X로 가리기

수정 전 입력 · alignment 열은 1부터

query	ACDEFGHIKLMN
A2	ACDeeEFGHIKLMN
A3	ACDE-GHIKLMN

query col 123456789012

mask cols: 5, 7, 10

A2 output: _____

문제 · 근거와 함께 답하세요

③ A2의 alignment 5·7·10열을 X로 바꾼
원문 문자열을 쓰세요.

Query·소문자 ee·A3의 기존 gap은
어떻게 하나요?

어느 열의 빈도와 다른 열과의 조합
정보가 가려지나요?

5·7·10은 원문 문자 위치가 아닌 query alignment 열입니다. 컴퓨터에서는 masked.a3m과 대조합니다.

정답·해설 · A2의 완성 문자열과 열 번호

query	ACDEFGHIKLMN	(unchanged)
A2 before	ACDeeEFGHIKLMN	
A2 after	ACDeeEXGXIKXMN	
A2 aligned	ACDEXGXIKXMN	
A3 after	ACDE-GXIKXMN	

alignment 5·7·10열(F·H·L) → A2 원문 7·9·12번째 글자를 X로 변경
ee는 alignment 3열 뒤/4열 앞 insertion: 원문 4·5번째 글자이며 alignment 열은 없음
열 번호는 1부터 셉니다. A2 결과는 ACDeeEXGXIKXMN입니다.

소문자 ee·query 전체·기존 gap을 보존합니다. A3의 5열 -도 그대로입니다.

흔한 오류: 원문 5·7·10번째 글자를 가리거나, 먼저 대문자화해 insertion을 alignment 열로 세기.

정답·해설 · X로 가린 정보와 남긴 정보

확인 항목	정답과 이유
Query	전체 보존: 같은 target에서 homolog 정보만 바꾸기 위해
소문자 ee	보존: insertion 정보를 남기고 alignment 열 대응을 유지
기존 gap -	보존: X와 뜻이 다름. 열을 삭제하거나 residue를 새로 넣지 않음
5·7·10열	homolog residue 정체를 X로 가려 빈도·다른 열과의 조합 정보를 약화

원본 MSA를 control으로 남깁니다. X는 residue 정체를 가린 표식이며 gap과 같지 않습니다.

이것은 문자열 생성 실습입니다. AFsample2 실행·특정 contact 제거·대안 structure 발견을 뜻하지 않습니다.

SPEACH_AF와 AFsample2는 같은 편집이 아니다


비교	SPEACH_AF 원 방법	AFsample2
편집 기호	A: alanine	X: unknown
위치 선택 근거	초기 structure의 contact 정보	무작위 MSA 열
Query 처리	원 코드에서 함께 편집	첫 query 행 유지
공통 해석	새 structure 후보 탐색	검증 필요한 후보

SPEACH_AF: structural information을 이용한 alanine 편집

AFsample2: 선택한 MSA 열을 unknown X로 가림

원래 SPEACH_AF는 query도 편집한다는 예외를 확인한다.

논문 그림 읽기: AFsample2의 입력과 출력



FASTA 제목에 open을 쓰면 열릴까?

```
>sample_open  
ACDEFGHI
```

```
>sample_closed  
ACDEFGHI
```

교육용 가상 sequence. 같은 문자열에 붙인 이름 두 개이며, open/closed 상태를 지정한 입력이 아니다.

Header는 식별자이며 conformational state 명령문이 아니다.

MSA 내용과 예측 설정이 같으면 이름만으로 상태를 지정하지 못한다.

complex에서는 header의 species 정보가 pairing에 쓰일 수 있다.

Seed·dropout·template도 별도 요인이다

요인	바뀌는 것	주의할 해석
Random seed	stochastic 계산의 선택	다른 seed ≠ 다른 물리 상태
Inference dropout	계산 중 stochastic 교란	온도·시간을 지정하지 않음
Template	참고 structural information	유도된 상태·평가 누출 점검
Recycles	예측 내부 반복	molecular motion 시간과 다름

- Seed: 반복마다 사용되는 난수의 출발점
- Dropout: 지원 구현에서 inference 중 일부 연산을 무작위로 끄
- Template: 이미 알려진 structural information이 입력에 추가됨

AF2 근거를 AF3에 그대로 옮길 수는 없다

범위	확인된 내용	필요한 추가 확인
AF2 방법 연구	Subsampling·cluster·mask 사례	새 target에서 대조 비교
로컬 AF3	Custom MSA 입력 지원	구현·설정·model 차이
AF3 연구 확장	AFsample3 저장소 존재	target별 검증·근거 수준

이 단원의 대표 논문들은 AF2를 시험했다.

로컬 AF3는 custom MSA를 받을 수 있다.

AF3용 구현의 존재와 검증된 성능을 구별한다.

활동지 7 · 후보 8개를 confidence와 함께 판독

가상 180 residue target · 전체 8개 후보

ID	MSA	pLDDT	거리 Å	PAE Å
F1	원본	91	8.2	3.1
F2	원본	92	8.6	3.0
S1	얇음	88	16.4	4.4
S2	얇음	50	22.0	18.0
A1	라벨 A	90	8.5	3.3
B1	라벨 B	89	16.0	4.0
M1	X mask	87	15.8	5.2
M2	X mask	49	24.0	19.0

문제 · 근거와 함께 답하세요

- ① 서로 다른 거리의 후보 묶음을 찾으세요. 큰 거리만 보고 S2/M2를 선택해도 될까요?
- ② 평균 pLDDT가 가장 높은 model 하나만 남기면 무엇을 놓칠 수 있나요?
- ③ 8개 중 3개가 비슷하면 equilibrium population은 3/8인가요? 더 필요한 근거는?

거리: 40–140번 C α / PAE: 20–70과 110–160 사이 양방향 평균. 실제 예측이나 앞의 A3M에서 계산한 값이 아닙니다.

정답·해설 · 거리와 confidence를 함께 비교

후보 묶음	가상 수치	판단 근거
F1 · F2 · A1	거리 8.2 · 8.6 · 8.5 Å	가까운 거리 후보로 묶어 검토
S1 · B1 · M1	거리 16.4 · 16.0 · 15.8 Å	첫 묶음과 다른 배치인지 검토
S2 · M2	pLDDT 50 · 49 PAE 18 · 19 Å	큰 거리 22 · 24 Å만으로 대안 structure라 부르기 어려움

F2만 고르면 S1 등의 다른 배치 후보를 놓칩니다. 각 묶음에서 대표 후보를 남깁니다.

한 개의 거리는 structure 전체를 요약하지 못합니다. 같은 구간을 alignment해 domain 배치와 contact를 비교합니다.

정답·해설 · 3/8은 equilibrium population이 아니다

질문	답과 이유
약16 Å 후보가 3/8개?	S1·B1·M1: 생성물에서 37.5%라는 뜻
open state가 37.5% 존재?	판정 불가: model 생성 빈도가 물리적 equilibrium distribution라는 근거가 없음
조건별 후보를 더 비교하려면?	같은 query·model·seed 집합·생성 수로 반복하고 입력 조건을 기록
실제 structure·population을 판단하려면?	structure의 물리적 타당성과 독립적인 structure·spectroscopy 등 실험 근거 확인

MSA·seed·선별 기준을 바꾸면 생성 비율도 바뀔 수 있습니다. 높은 pLDDT도 상태의 존재 확률은 아닙니다.

최종 설명 활동

종아·구두 응답 또는 컴퓨터 실습

“Ortholog만 모으면 covariation이 곧 direct contact이다.”

“MSA cluster가 3개이므로 conformational state도 3개다.”

“예측 100개 중 20개가 열렸으니 population은 20%다.”

각 주장에 빠진 근거를 한 문장씩 적으세요.

정답·해설 · 세 주장을 근거에 맞게 고치기

원래 주장	빠진 근거와 수정한 설명
Ortholog의 covariation = direct contact	Common ancestor·indirect association도 covariation을 만듭니다. Contact는 structure로 검증해야 합니다.
MSA cluster 3개 = conformational state 3개	Sequence를 나눈 결과입니다. 서로 다른 입력에서도 같은 structure가 나올 수 있어 예측 coordinates를 따로 비교합니다.
100개 중 20개 = equilibrium population 20%	생성 빈도일 뿐입니다. Equilibrium sampling의 근거와 실험 검증이 필요합니다.

좋은 답은 “틀렸다”에서 끝나지 않고, 무엇을 관측했으며 어떤 근거가 더 필요한지 설명합니다.

오늘 배운 내용

evolutionary relationship은 common ancestor에서 일어난 사건으로 판단
covariation은 단서이며 common ancestor·functional divergence를 함께 해석
MSA 조작은 서로 다른 structure 가설을 탐색하는 도구
후보 structure는 confidence·reproducibility·실험 근거로 평가

논문과 실행 문서

Jumper et al. (2021), Highly accurate protein structure prediction with AlphaFold

<https://www.nature.com/articles/s41586-021-03819-2>

Mariani et al. (2013), IDDT: a local superposition-free structure comparison score

<https://pmc.ncbi.nlm.nih.gov/articles/PMC3799472/>

ColabFold official repository

<https://github.com/sokrypton/ColabFold>

EMBL-EBI / Google DeepMind training: pLDDT, Understanding local confidence

www.ebi.ac.uk · [원문 열기](#)

EMBL-EBI / Google DeepMind training: PAE, A measure of global confidence

www.ebi.ac.uk · [원문 열기](#)

전체 출처와 논문 그림 라이선스: content/sources.json 및 발표자 노트