


MSA와 protein structure 예측 · 학생 활동지

1. evolution 설명 직후 · speciation과 gene duplication

이름: _____ 조: _____ 날짜: _____

상황 A: gene duplication(D)이 speciation(S)보다 먼저 일어났습니다.



H = 사람 lineage, M = 생쥐 lineage. 가지 길이는 시간·similarity를 나타내지 않습니다.

1. H_A-M_A, H_A-H_B, H_A-M_B의 관계를 분류하고 판단한 사건을 쓰세요.

상황 B: 먼저 H와 M으로 speciation했고, H의 gene만 H1·H2로 gene duplication되었습니다.

2. H1-H2, H1-M, H2-M의 관계를 쓰세요. M에 대한 H1·H2의 관계도 설명하세요.

3. “sequence가 가장 비슷한 두 gene은 반드시 ortholog다.”에 빠진 정보는 무엇인가요?

교육용 가상 자료입니다. 답은 근거와 함께 적으세요.

MSA와 protein structure 예측 · 학생 활동지

2. MSA 설명 직후 · A3M 읽기

이름: _____ 조: _____ 날짜: _____

아래는 12개 alignment 열을 가진 가상 자료입니다. 실제 예측용 protein이 아닙니다.

```
>query
ACDEFGHIKLMN
>example_A1 group=A
ACDEFGHIKLMN
>example_A2 group=A
ACDeeEFGHIKLMN
>example_A3 group=A
ACDE-GHIKLMN
>example_B1 group=B
ACDEYGHILXN
>example_B2 group=B
ACDttEYGHIL-N
>example_B3 group=B
AC-EYGHILXN
```

1. Query 포함 행 수: _____ Homolog 행 수: _____ alignment 열 수: _____

2. A2의 ee는 몇 번째 alignment 열 직전에 있나요? 소문자를 대문자로 바꾸면 왜 안 되나요?

3. A3의 gap과 B1의 X가 있는 alignment 열 번호와 각각의 의미를 쓰세요.

4. 같은 행을 여러 번 복제해 depth를 키우면 독립적인 evolutionary information이 늘어나나요?

MSA와 protein structure 예측 · 학생 활동지

3. Coevolution 설명 직후 · evolutionary relationship와 두 열의 패턴

이름: _____ 조: _____ 날짜: _____

가상 자료: A/B gene duplication 후 H·M·R·F 네 species로 분화했습니다. 각 species에 A와 B가 하나씩 있습니다. i와 j는 같은 protein 안의 두 alignment 위치입니다.

자료: 두 paralog subfamily를 합친 8행

gene	i	j
A_H	D	K
A_M	D	K
A_R	D	K
A_F	D	K
B_H	K	D
B_M	K	D
B_R	K	D
B_F	K	D

대조 자료: 다른 가상 8행

i, j	행 수
D, D	2
D, K	2
K, D	2
K, K	2

D = Asp, K = Lys
한 행은 한 gene의 두 위치입니다.
두 표 모두 실제 관측값이 아닙니다.

1. 왼쪽 자료: $P(D_i) = \underline{\hspace{1cm}}$ $P(K_j) = \underline{\hspace{1cm}}$ 실제 $P(D_i, K_j) = \underline{\hspace{1cm}}$
독립이라면 $P(D_i) \times P(K_j) = \underline{\hspace{1cm}}$. 대조 자료와 무엇이 다른가요?

2. A_H-A_M, A_H-B_M의 evolutionary relationship는? A/B를 따로 보면 variation가 남나요?

3. 왼쪽의 8행은 “독립적인 compensatory change 8번” 또는 “direct contact”의 증거인가요?
패턴이 common ancestor로부터 함께 내려왔을 가능성을 설명하세요.

4. Ortholog만 모으면 phylogenetic effects가 사라질까요? 더 필요한 근거를 써 보세요.

MSA와 protein structure 예측 · 학생 활동지

4. Depth → clustering → masking · 설명마다 한 항목씩

이름: _____ 조: _____ 날짜: _____

컴퓨터: Alprediction/practice/에서 생성 후, 설명한 조건의 파일을 차례로 봅니다.

```
sh run_practice.sh
# custom run
python3 msa_lab.py --depth 4 --seed 7 \
  --out runs/student01
```

컴퓨터 없이: query와 A2, A3, B1을 선택했다고 가정합니다.
여기 A/B는 임의 라벨이며, 3쪽의 evolutionary history가 주어진 subfamily와 별개입니다.

1. Depth 설명 직후: subsample.a3m의 첫 행은 무엇이며, 유지하는 이유는?

2. Clustering 설명 직후: group_A/B.a3m의 사전 라벨 분리와 AF-Cluster의 차이는?

3. Masking 설명 직후: homolog의 5·7·10열을 X로 가린 A2를 쓰고
masked.a3m과 비교하세요. Query·소문자 ee·기존 gap은 어떻게 하나요?

4. MSA 조건을 비교할 때 고정하거나 기록할 항목 세 가지 이상을 쓰세요.

교육용 가상 자료입니다. 답은 근거와 함께 적으세요.

MSA와 protein structure 예측 · 학생 활동지

5. IDDT 계산 → pLDDT 예측

이름: _____ 조: _____ 날짜: _____

가상 IDDT-Ca 예제: 중심 residue i의 neighbor a·b·c·d 네 쌍만 평가합니다.
reference structure에서 15 Å 미만인 쌍을 선택하며, coordinates가 모두 있다고 가정합니다.

각 쌍의 absolute distance error를 구하고 0.5·1·2·4 Å보다 작은지 각각 셉니다.
이 예제의 IDDT_i = 네 쌍의 통과 횟수 합 / (4쌍 × 4기준).
표는 설명과 함께 채우고, 1번만 1분 핵심 실습으로 풀니다. 2-4번은 확장용입니다.

neighbor	reference distance (Å)	predicted distance (Å)	absolute error (Å)	통과 횟수 / 4
a	4	4.2	_____	_____
b	7	7.8	_____	_____
c	10	11.5	_____	_____
d	14	17	_____	_____

표의 IDDT_i = _____ / 16 = _____ (0-1). 100점 척도로 표시하면 _____.

1. [1분] d의 predicted distance만 17 → 19 Å로 바꿉니다. d는 neighbor 계산에 [포함 / 제외].
새 IDDT_i는 [9/16 또는 9/12]이며, 100점 척도에서는 _____입니다.

2. [확장] IDDT를 직접 계산할 때와 pLDDT를 inference할 때,
비교할 reference structure가 필요한 쪽은 무엇인가요?

3. [확장] pLDDT 90을 “coordinates가 정확할 확률 90%” 또는
“이 conformational state의 population 90%”로 해석해도 될까요?

4. [확장] AF2의 50개 구간 중 3개 중심만 보인 교육용 근사입니다.
중심 c: 0.49, 0.69, 0.89 / 확률 p: 0.10, 0.20, 0.70
나머지 매우 작은 확률은 생략했습니다. $100 \times \sum(p \times c) =$ _____.
가장 확률이 큰 한 구간의 중심만 사용한 값과 같은가요?

교육용 가상 자료입니다. 답은 근거와 함께 적으세요.

MSA와 protein structure 예측 · 학생 활동지

6. pLDDT → PAE · 설명 직후 나누어 읽기

이름: _____ 조: _____ 날짜: _____

domain 개념을 12개 위치로 축약한 가상 예제입니다. 실제 protein-inference 결과가 아니며 앞의 12열 A3M과 별개입니다. A: 1–5, linker: 6–7, B: 8–12.

구간	residue 위치	각 residue의 pLDDT (0–100)
A	1–5	94, 93, 91, 90, 88
linker	6–7	43, 39
B	8–12	86, 92, 94, 93, 91

1. pLDDT 설명 직후: 어느 구간의 coordinates를 특히 조심해서 해석해야 하나요?
이 값만으로 그 구간이 disorder하거나 빠르게 움직인다고 확정할 수 있나요?

조건 P의 PAE (Å): 전체 12×12 중 3·4·9·10번 위치만 뽑은 4×4 표입니다.
행 i = 오차를 평가할 위치, 열 j = alignment anchor. 다음은 PAE 설명 뒤 풀니다.

i / j	A3	A4	B9	B10	
A3	0	1	18	20	A3 = A 구간의 3번 위치 B9 = B 구간의 9번 위치
A4	1	0	19	21	
B9	24	23	0	2	수치는 모두 가상입니다. 표의 방향부터 확인하세요.
B10	22	24	2	0	

2. $PAE(A3, B9) = \text{ } \text{Å}$, $PAE(B9, A3) = \text{ } \text{Å}$.
각각 어느 위치를 기준으로 한 예상 오차인가요? residue 사이 거리인가요?

3. A/B 내부와 A–B 사이 PAE를 비교하세요. 높은 per-region pLDDT와 큰 구간 간 PAE가 동시에 나오는 것은 모순인가요?

4. 조건 Q는 pLDDT가 같고, 위 표의 대각선 밖 PAE가 모두 1–3 Å입니다.
무엇에 더 자신이 있나요? binding·특정 상태의 존재나 population도 확정되나요?

MSA와 protein structure 예측 · 학생 활동지

7. Confidence를 함께 보기 · 가상 예측 결과 판독

이름: _____ 조: _____ 날짜: _____

가상 180 residue target의 독립 사고 실험입니다. 앞의 A3M에서 계산한 결과가 아닙니다.

거리 = 40–140번 C α 거리. PAE = 20–70과 110–160 구간 사이 두 방향 평균.

ID	조건	pLDDT	거리 (Å)	PAE (Å)
F1	원본 MSA	91	8.2	3.1
F2	원본 MSA	92	8.6	3.0
S1	얇은 MSA	88	16.4	4.4
S2	얇은 MSA	50	22.0	18.0
A1	사전 라벨 A	90	8.5	3.3
B1	사전 라벨 B	89	16.0	4.0
M1	Homolog X masking	87	15.8	5.2
M2	Homolog X masking	49	24.0	19.0

1. 서로 다른 후보 묶음을 골라 보세요. 큰 거리만 보고 S2/M2를 선택해도 될까요?

2. 평균 pLDDT가 가장 높은 structure 하나만 남길 때 무엇을 놓칠 수 있나요?

3. 8개 중 3개가 비슷한 거리라면 equilibrium population이 3/8인가요? 추가 근거를 쓰세요.

교육용 가상 자료입니다. 답은 근거와 함께 적으세요.